

*M1 Analyse spatiale :
Dossier Spatialisation-Géostatistiques*

*PREVISIONS DES PRECIPITATIONS
JOURNALIERES EN NOUVELLE-AQUITAINE EN
JANVIER 2100 : MODELISATION D'APRES LE
SCENARIO CLIMATIQUE RCP 8,5*

Table des matières

Table des matières	0
Introduction	1
I. Présentation de la zone d'étude	2
II. Données et méthodologie.....	2
1. Données.....	2
2. Synthèse méthodologique de la démarche adoptée par méthodes d'interpolations	3
2.1. Méthode statistique par le modèle de régression linéaire.....	3
2.1.1. Autocorrélation globale et locale des résidus du modèle de régression linéaire	4
2.2. Méthode déterministe par l'Inverse de la distance (IDW).....	5
2.3. Méthode géostatistique par le Krigeage	5
III. Résultats	6
1. Interpolation statistique par le modèle de régression linéaire	6
2. Autocorrélation globale et locale des résidus du modèle de régression linéaire	9
3. Interpolation déterministe par l'inverse de la distance (IDW)	10
1. Interpolation géostatistique par le krigeage universel	11
IV. Interprétation statistique et spatiale des résultats.....	11
Conclusion	12
Bibliographie.....	I
Annexe.....	II

Introduction

Le changement climatique constitue un enjeu global majeur en raison de ses impacts sur les régimes hydrologiques et sur la répartition spatiale des précipitations. À l'horizon 2100, les projections climatiques anticipent des modifications significatives des régimes de précipitations, avec des disparités marquées selon les régions et les saisons. Ces transformations peuvent affecter la disponibilité des ressources en eau, les pratiques agricoles ainsi que la gestion des risques liés aux inondations et à la sécheresse (Rubel et Kotteck, 2010). La compréhension de ces changements, en particulier au niveau régional, est cruciale pour fournir des outils de gestion adaptés aux besoins locaux.

La spatialisation des données climatiques a été largement étudiée, testant diverses méthodes d'interpolation à travers le monde (Laala et al., 2017). Nalder et Wein (1998) ont montré qu'aucune méthode d'interpolation ne s'adapte à toutes les régions à travers une modélisation des températures et précipitations du nord-ouest canadien.

Les données climatiques, telles que les précipitations journalières, sont souvent issues de mesures réalisées dans un réseau de stations météorologiques inégalement réparties dans l'espace. Cette hétérogénéité spatiale impose le recours à des méthodes d'interpolation pour produire des estimations continues à partir de données ponctuelles. Les méthodes de spatialisation et de géostatistique, en s'appuyant sur la première loi de la géographie énoncée par Tobler (1970) – selon laquelle « tout interagit avec tout, mais les choses proches interagissent mieux que les objets éloignés » – fournissent des outils précieux pour modéliser des variables dépendantes.

La région Nouvelle-Aquitaine, située au sud-ouest de la France, présente une grande diversité géographique, qui inclut des zones littorales, des plaines et des massifs montagneux. Ces variations géographiques peuvent exercer une influence directe sur les régimes de précipitations. Nous verrons dans ce travail quel type de modèle rend le mieux compte de l'influence de ces paramètres sur le régime des précipitations.

Ce dossier a pour objectif principal de spatialiser les projections de précipitations totales journalières dans la région Nouvelle-Aquitaine, pour le mois de janvier 2100, en utilisant des données du modèle ALADIN-Climat selon le scénario de changement climatique le plus péjoratif (RCP 8,5). La méthode de spatialisation principale repose sur une régression linéaire multiple, intégrant des variables explicatives telles que l'altitude, la latitude, la longitude et l'humidité spécifique à 2 mètres. Les résultats issus de cette méthode seront comparés à ceux obtenus avec des techniques d'interpolations déterministe, comme la pondération de l'inverse de la distance (IDW), et d'interpolation géostatistique comme le krigeage.

L'analyse comprendra une évaluation de l'autocorrélation spatiale des résidus du modèle de régression, à l'aide de l'indice I de Moran (autocorrélation globale) et les indicateurs LISA (autocorrélation locale), qui est une hypothèse de la validité d'une régression linéaire. Nous vérifierons également la non-colinéarité des variables grâce au facteur d'inflation de la variance, la normalité et l'homoscédasticité des résidus du modèle. Enfin, les

provient de la BD Admin Express (2021) et les données altitudinales au pas de 250 mètres proviennent de la BD ALTI fournie par l'IGN (2018) et constitue une des variables explicatives.

2. Synthèse méthodologique de la démarche adoptée pour nos méthodes d'interpolation

Dans le cadre de cette étude, nous avons choisi d'interpoler la moyenne des précipitations sur l'ensemble du mois de janvier dans son intégralité plutôt que sur une seule journée. Nous savons qu'une station qui enregistre 00 mm de pluie sur une journée est une information en soi, seulement nous avons pris le parti de prendre l'ensemble du mois de janvier pour avoir une meilleure estimation de la tendance des précipitations. L'échelle temporelle du mois nous paraît pertinente pour analyser les tendances des précipitations en janvier, au cœur de l'hiver de l'hémisphère nord. Nous avons également extrait les données de précipitations avec un tampon de 10 kilomètres autour des limites administratives de la région, afin de mieux alimenter le modèle sur les marges de notre zone d'étude. Après avoir obtenu les données de précipitations pour notre zone d'étude uniquement, nous les avons exportées par date (du 01 au 31 janvier) au format « csv » à l'aide du logiciel ArcGIS Pro. Cela a donné lieu à 31 fichiers, que nous avons consolidés en un seul fichier Excel. Ensuite, avec RStudio, nous avons calculé la moyenne des précipitations et de l'humidité spécifique à 2 mètres de l'ensemble des journées du mois pour chaque station de la zone d'étude. Pour convertir ces données ponctuelles en représentations surfaciques continues, nous avons mis en œuvre trois méthodes d'interpolation : l'interpolation statistique, l'interpolation déterministe et l'interpolation géostatistique. La comparaison des différentes méthodes de spatialisation par leurs métriques statistiques associées nous permettra de connaître leurs avantages, inconvénients mais aussi leur fiabilité et efficacité.

2.1. Méthode statistique par le modèle de régression linéaire

Cette méthode exploite les relations entre la précipitation (variable dépendante) et les variables explicatives disponibles : l'altitude, la longitude, la latitude et l'humidité spécifique à 2 mètres. L'application du modèle de régression linéaire aux données disponibles, nous permet d'obtenir une équation de la forme : $Y = aX + d$ (pour une seule variable explicative) et $Y = aX1 + bX2 + cX3 + \dots + d$ (pour plusieurs variables explicatives), où Y est la variable estimée, X les variables explicatives, a , b et c les coefficients des variables explicatives et d l'ordonnée à l'origine.

Pour créer notre modèle, nous avons d'abord établi un maillage de 500x500 mètres à l'échelle de la région Nouvelle-Aquitaine. Ce maillage sert à intégrer les données explicatives et à spatialiser les précipitations. Les données d'altitude comprises à l'intérieur des mailles sont jointes par localisation sous la base de l'agrégation par la moyenne, tenant compte de leur résolution plus fine (en moyenne 2 points d'altitudes extrait du MNT pour chaque maille). De plus, les données ponctuelles de précipitation sont intégrées au maillage après projection dans le système cartographique Lambert II étendu (projection métrique). Après la jointure, les coordonnées de la latitude et la longitude de chaque maille sont calculées. Toutes les mailles n'ont pas de données de précipitation, celle qui en contiennent (1 560) constitueront alors le jeu d'apprentissage pour notre modèle.

Dans un second temps, nous avons analysé les corrélations statistiques entre les variables explicatives. Le tableau 1 présente la matrice de corrélation entre les variables explicatives.

Tableau 1: Matrice de corrélation entre les variables explicatives. Les valeurs en orange montrent la forte corrélation existante entre les variables.

Variables	Altitude	Humidité spécifique	Longitude_X	Latitude_Y
Altitude	1,00			
Humidité spécifique	-0,88	1,00		
Longitude_X	0,40	-0,61	1,00	
Latitude_Y	-0,17	-0,19	0,39	1,00

La première remarque importante est qu'il existe une forte colinéarité négative entre « humidité spécifique » et « altitude », ainsi qu'entre « humidité spécifique » et « longitude ». Selon Foucart (2006), ce problème risque de perturber les estimations des paramètres du modèle. Nous avons donc complété cette analyse en réalisant un test de colinéarité entre les précipitations journalières et les variables explicatives pour identifier celles corrélées à la précipitation. Ensuite, nous avons calculé le facteur d'inflation de la variance (VIF) de ces variables explicatives (tableau 2) pour vérifier l'absence de multicollinéarité.

Tableau 2 : A droite, la matrice de corrélation entre la variable indépendante (précipitation) et les variables explicatives. La couleur orange montre les variables explicatives les mieux corrélées à la précipitation. A gauche, VIF des variables les mieux corrélées à la précipitation.

Variables	précipitation	Altitude	Humidité	Longitud_X	Latitude_Y
précipitation	1,00				
Altitude	0,62	1,00			
Humidité	-0,34	-0,88	1,00		
Longitud_X	-0,16	0,40	-0,61	1,00	
Latitude_Y	-0,73	-0,17	-0,19	0,39	1,00

Variables	VIF
Altitude	1,028477
Latitude_Y	1,028477

La première remarque qui s'impose est que les variables explicatives altitude et latitude sont les mieux corrélées à la précipitation. L'altitude est corrélée positivement et la latitude négativement. Cela signifie qu'une augmentation de l'altitude entraîne une augmentation de la précipitation, tandis qu'une augmentation de la latitude entraîne une diminution de celle-ci. De plus, le VIF de ces variables est faible ($VIF < 5$), ce qui indique que les coefficients de régression ne sont pas augmentés par la présence d'une colinéarité. Par conséquent, ces deux variables ont été conservées pour le calcul du modèle.

2.1.1. Autocorrélation globale et locale des résidus du modèle de régression linéaire

L'autocorrélation spatiale des résidus permet de détecter si le modèle de régression linéaire capture correctement les variations des données. **L'absence d'autocorrélation** indique que le modèle a bien représenté les relations entre les variables explicatives et la variable à prédire. A contrario, **la présence d'autocorrélation** signale des relations non linéaires, des variables manquantes, ou des dépendances spatiales mal prises en compte. Le calcul de l'autocorrélation globale et locale a été réalisé sur le logiciel GeoDa. La définition du voisinage est importante dans l'application des indices de Moran globaux et locaux car elle influence les observations que l'on peut faire. Nous avons donc effectué plusieurs tests, notamment avec la méthode du nombre k de plus proches voisins. Nous avons testé $k = 2 ; 4$ et 8 . Plus on augmente le nombre de voisins plus on

augmente la probabilité d'obtenir des observations hétérogènes dans le voisinage (et donc des indices de Moran plus faibles), mais c'est également une façon de garantir que les indices recueillis reflèteront mieux la réalité. Nos points de mesures sont assez distants les uns des autres mais ils sont relativement bien répartis dans l'espace. Nous avons donc retenu **$k=8$** car nous avons observé sur le graphe de connectivité que c'est le nombre qui permettait d'avoir des voisins les mieux répartis dans toutes les directions des points cardinaux.

2.2. Méthode déterministe par l'Inverse de la distance (IDW)

L'interpolation déterministe par l'inverse de la distance (IDW) consiste à estimer les valeurs inconnues en fonction des valeurs des points mesurés, pondérées par l'inverse de leur distance. Plus un point est proche d'un point connu, plus son influence est forte. Cette méthode est entièrement basée sur la distance spatiale entre les points et ne nécessite pas de variables explicatives contrairement à l'interpolation statistique. Nous nous concentrons donc sur la valeur moyenne mensuelle des précipitations de chaque point.

L>IDW repose sur deux paramètres principaux : le nombre de voisins et la puissance de pondération, qui détermine le poids accordé aux points en fonction de leur distance. Une puissance plus élevée donne une importance plus grande aux points proches, rendant l'interpolation plus localisée.

Ces paramètres influencent directement les résultats de l'interpolation et doivent être choisis avec soins pour éviter le surapprentissage. Après des tests comparatifs, nous avons fixé le nombre **minimum de voisin à 5** et **maximum à 15** et la **puissance à 2**, ce qui assure un bon équilibre entre précision (erreur quadratique moyenne minimale) et continuité spatiale.

2.3. Méthode géostatistique par le Krigeage

Contrairement aux approches déterministes comme l>IDW, le krigeage prend en compte l'autocorrélation spatiale des données, ce qui permet une estimation plus précise et mieux adaptée aux variations locales (Gratton Y., 2014). En utilisant à nouveau le maillage avec les valeurs de précipitations, nous avons réalisé l'interpolation par le Krigeage. Premièrement, il faut prendre en compte les caractéristiques de notre jeu de donnée pour le choix du krigeage final :

- ➔ **La normalité du jeu de données** : évaluée à l'aide d'indicateurs statistiques centraux et de dispersion (moyenne, valeurs maximales et minimales) et d'histogramme.
- ➔ **L'autocorrélation spatiale** : mesurée à l'aide du semi-variogramme.
- ➔ **La stationnarité intrinsèque** : évaluée en cartographiant l'écart-type (Annexe 1). Cependant, une forte stationnarité locale a été observée, écartant l'utilisation d'un krigeage bayésien empirique.
- ➔ **La stationnarité de la moyenne** : évaluée à travers la construction du diagramme de Voronoï (Annexe 2). Cependant, le diagramme montre une faible stationnarité moyenne, rendant nécessaire l'utilisation d'un krigeage universelle, prenant en compte l'altitude car c'est l'un des principaux facteurs aux variations de la précipitation.

Le choix d'une équation de premier degré pour le krigeage universel s'appuie sur la présence d'une tendance spatiale globale qui caractérise nos données (car on sait qu'il existe une relation linéaire entre les précipitations

et l'altitude). Les paramètres (taille des classes de distance, nombre de classes de distance, le rayon de recherche) sont choisis en fonction de l'erreur quadratique moyenne la plus faible.

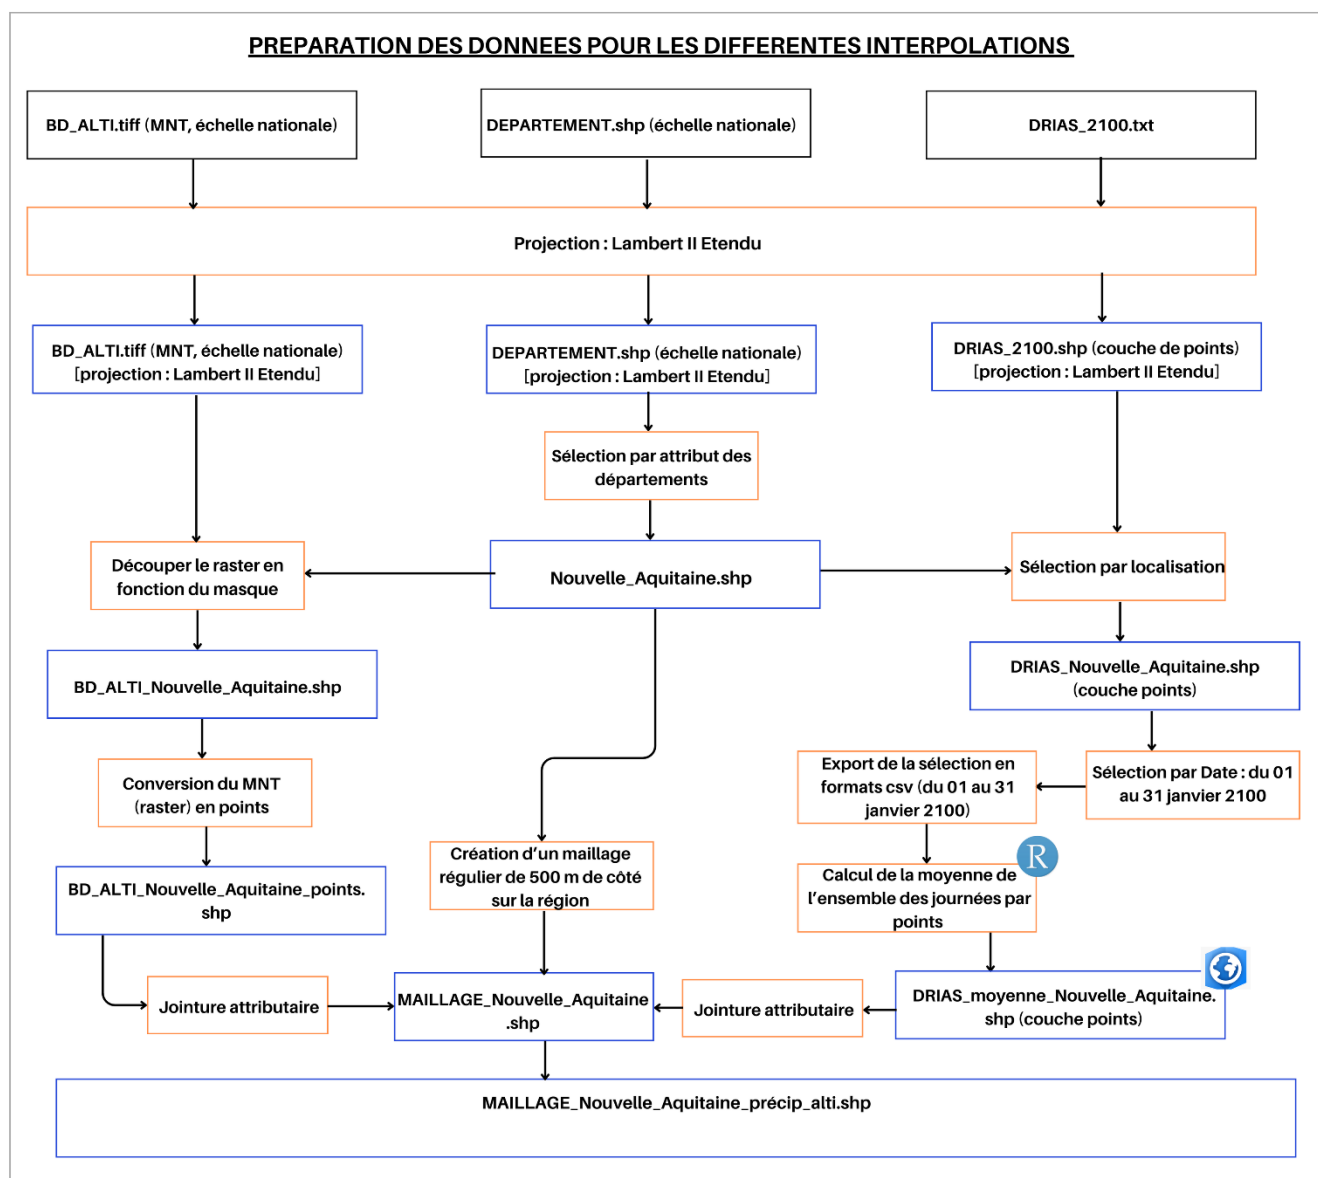


Figure 2 : Méthodologie de la préparation des données pour les différentes interpolations.

III. Résultats

1. Interpolation statistique par le modèle de régression linéaire

La mise en du modèle de régression linéaire a été calculé sur la base de deux variables explicatives (l'altitude et la latitude) en raison de leur significativité (valeur t-Statistique au-delà des intervalles supérieurs à 2 et inférieure à 2), l'absence de multicolinéarité (VIF < 5) et de la forte corrélation avec la variable indépendante (précipitation) (cf. 2.1, tableau 2).

Le modèle s'appuie sur une équation prenant en compte les coefficients des variables :

$$y = 0,004959X_1 - 0,000014X_2 + 34,010358$$

Où Y représente les précipitations estimées, X_1 représente la variable altitude et X_2 représente la variable latitude.

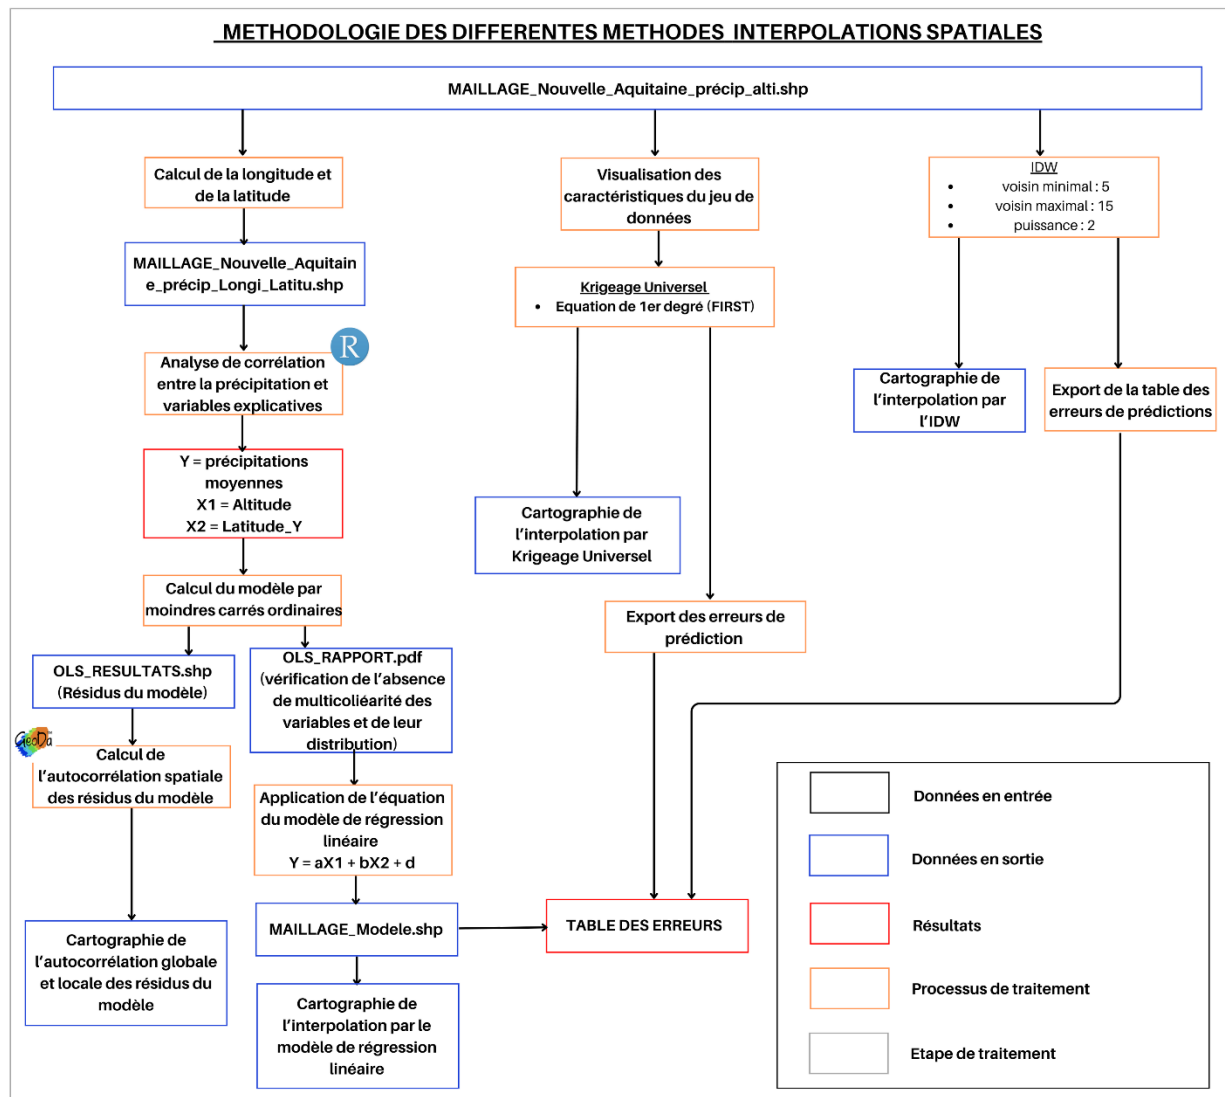


Figure 3 : Méthodologie du traitement des différentes méthodes d'interpolations spatiales.

Variable	Coefficient [a]	StdError	t-Statistic	Probability [b]	Robust_SE	Robust_t	Robust_Pr [b]	VIF [c]
Intercept	34,010358	0,540987	62,867281	0,000000*	0,627636	54,188005	0,000000*	-----
VALUE	0,004959	0,000118	42,140795	0,000000*	0,000294	16,857882	0,000000*	1,028477
LATITUDE	-0,000014	0,000000	53,608990	0,000000*	0,000000	-45,710918	0,000000*	1,028477

Figure 4 : Résumé du modèle de régression linéaire avec pour variable indépendante (la précipitation) et variables explicatives (l'altitude et la latitude).

De plus, le coefficient de détermination $R^2 = 0,78$ nous indique que seul 22 % de la variance n'est pas expliquée par notre modèle, on peut dire qu'il est performant et significatif ($p\text{-value} < 0,01$). Concrètement, 78% de la variabilité des précipitations du mois de janvier sont expliqués par notre modèle. Toutefois, d'autres paramètres tels que la constance de la variance des résidus ou homoscedasticité reste à vérifier. Tout d'abord, nous constatons à travers **le graphique des résidus standardisés par rapport aux valeurs prédites** (figure 5.a) que les valeurs surestimées (résidus positifs) sont analogues dans l'ensemble aux valeurs sous-estimées (résidus

négatif). De plus, il présente une forme générale en éventail, suggérant que le modèle linéaire fonctionne bien sur une grande majorité des observations, mais qu'il devient moins performant aux extrêmes.

La distribution des variables (figure 5.b) est aussi essentielle pour valider le modèle. La distribution de l'altitude montre une concentration des valeurs d'altitudes relativement basses, correspondant majoritairement aux plaines et plateaux de la zone d'étude. Les dernières valeurs d'altitude montrent une répartition hétérogène, correspondant aux montagnes localisées principalement au sud (massif des Pyrénées) et au nord-est (Massif central). Une corrélation positive marquée avec les précipitations traduit une augmentation des précipitations avec l'altitude, reflétant un gradient pluviométrique lié à l'effet orographique (précipitation plus importante sur les massifs montagneux comme les Pyrénées et le Massif central).

La distribution de la latitude est plus étendue, ce qui reflète la diversité géographique de la zone d'étude. Une corrélation négative marquée avec les précipitations traduit une diminution des précipitations avec l'augmentation de la latitude.

L'histogramme des valeurs standardisées (figure 5.c) montre que les valeurs des résidus suivent une loi normale avec une distribution assez symétrique autour de 0. Néanmoins, nous avons des valeurs

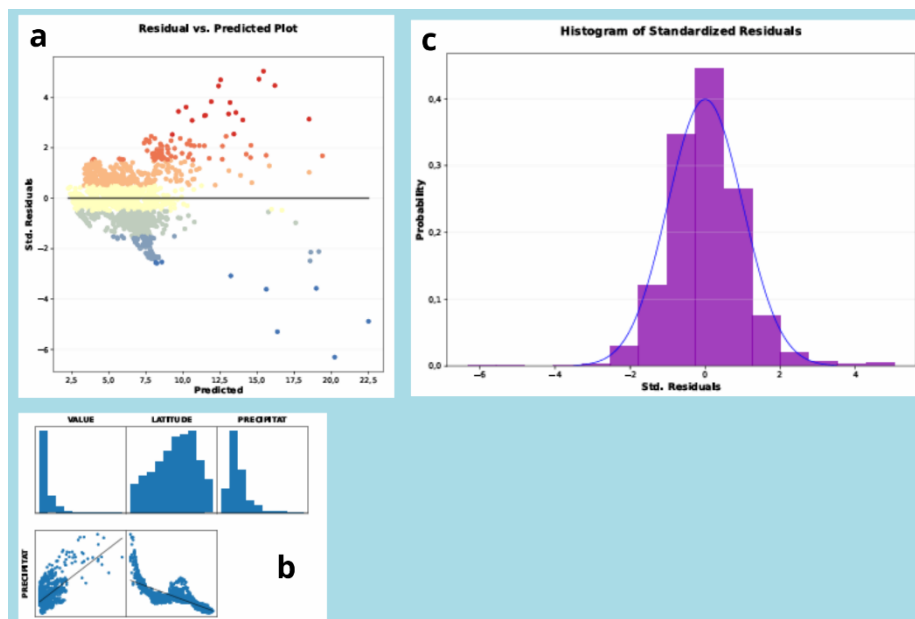
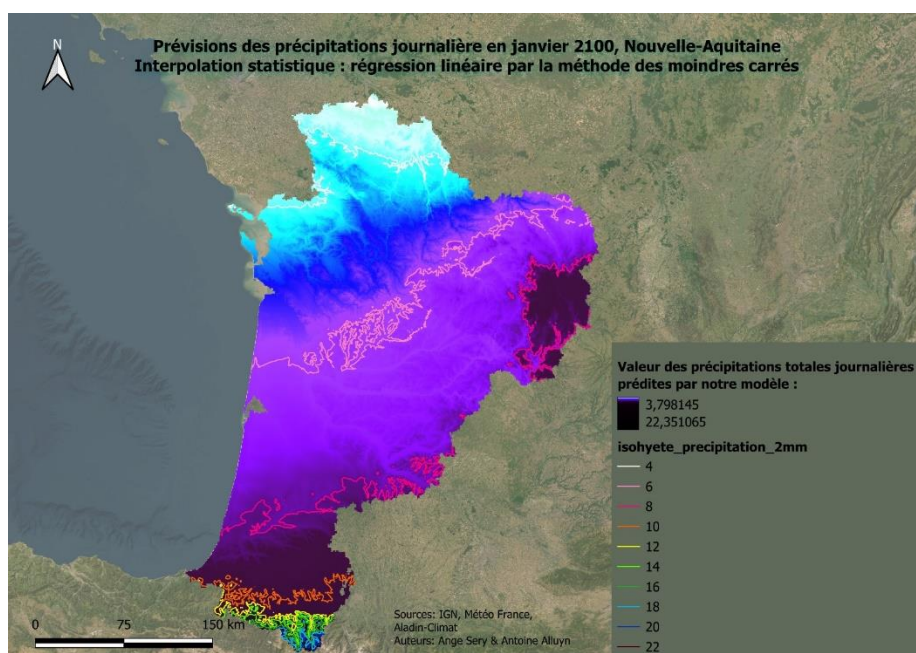


Figure 5 : Récapitulatif des résultats de la régression (Rapport OLS) : a) Graphique des valeurs résiduelle Vs prédite, b) Distribution et relation entre précipitation par rapport à l'altitude et la latitude, c) histogramme des résidus.

extrêmes des résidus positifs, suggérant que le modèle a tendance à surestimer les valeurs de précipitations.



La cartographie issue du modèle de régression linéaire (figure 6) spatialisant les précipitations moyenne de l'ensemble des journées du mois de janvier, révèle un gradient nord-sud, avec des précipitations maximales dans le sud, notamment dans les Pyrénées (22 mm) et des valeurs minimales vers le nord (2,8 mm). Ce résultat reflète l'effet de l'altitude, qui intensifie les précipitations à travers des processus comme l'ascension de l'air humide

Figure 6 : Interpolation statistique par la méthode de régression du modèle linéaire.

le long des reliefs, favorisant la condensation et les précipitations. Les isohyètes (lignes de même précipitation) indiquent une transition progressive dans les valeurs, particulièrement marquée entre les Pyrénées et les plaines du centre.

2. Autocorrélation globale et locale des résidus du modèle de régression linéaire

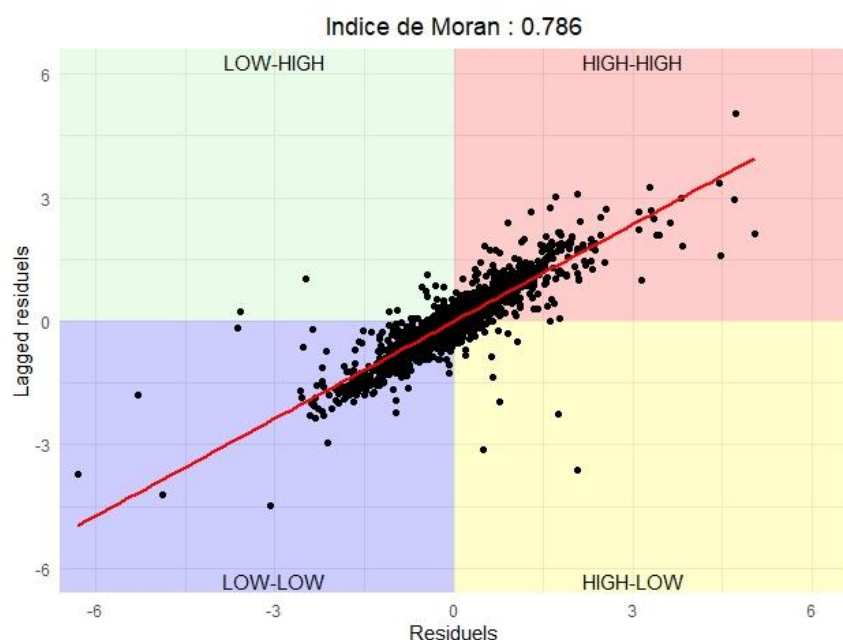


Figure 7 : Diagramme I de Moran global.

« **LOW – LOW** » regroupe des résidus négatives entourés de voisins également négatifs. La zone « **HIGH – LOW** », correspond à des valeurs résiduelles positives dans un contexte de valeurs résiduelles négatives et la zone « **LOW – HIGH** » indique des valeurs résiduelles négatives dans un contexte de valeurs résiduelles positives. Cependant, cet indice de Moran global, ne nous permet pas de connaître le détail de la structure spatiale des résidus. Nous appliquons donc un indice I de Moran local (LISA – Local Indicators of Spatial Association) pour détecter visuellement des potentiels regroupements significatifs de valeurs résiduelles identiques.

La figure 8 illustre la répartition spatiale de résidus dans notre zone d'étude. Les clusters rouge (HIGH – HIGH) correspondant à des zones où le modèle sous-estime les précipitations. Ces clusters apparaissent principalement dans les zones montagneuses, notamment dans le sud (proche des Pyrénées) et dans certaines parties de l'est associées au Massif Central. Cela

L'analyse de la carte d'autocorrélation globale des résidus (figure 7), réalisée avec le logiciel GeoDa, montre un indice de de Moran de 0.786 ce qui reflète une autocorrélation spatiale positive forte. Cela signifie que les résidus similaires, qu'ils soient élevés ou faibles ont tendance à se regrouper géographiquement. Le diagramme en quadrant met en évidence quatre types de relations spatiales : la zone « **HIGH – HIGH** » correspond à des valeurs résiduelles positives entourées de voisins également positive. La zone

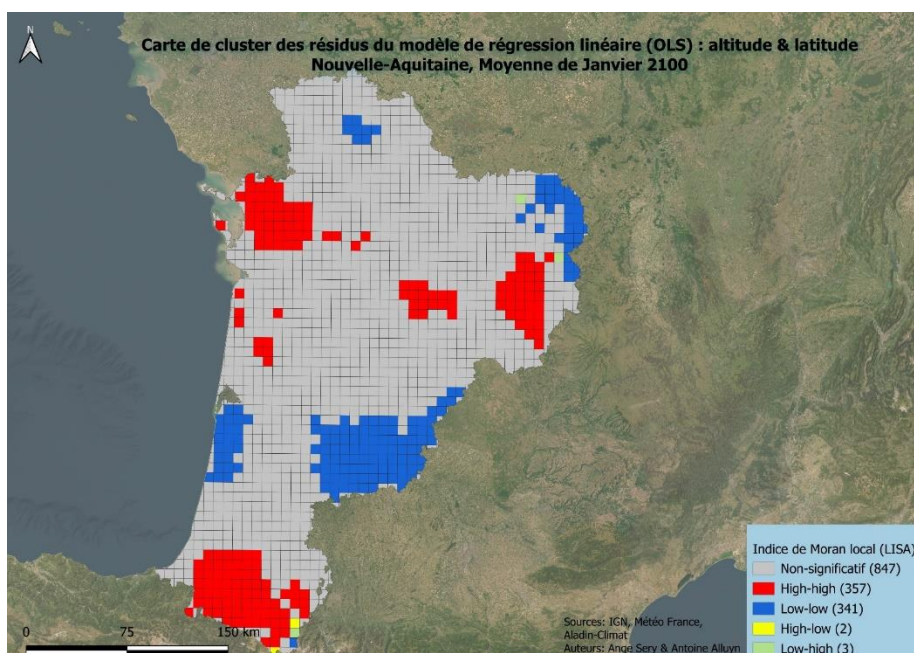


Figure 8 : Carte des clusters des résidus.

montre que la prise en compte de l'altitude, bien qu'importante, ne capture pas entièrement la complexité des variations spatiales liées aux précipitations, peut-être en raison d'autres facteurs non intégrés dans le modèle. Les zones en bleues (LOW-LOW) indiquent des clusters de résidus négatifs, où le modèle surestime les précipitations. Ces zones se trouvent majoritairement dans les plaines et les moyennes altitudes, particulièrement dans le centre le nord de la région. Les zones marginales en jaune (HIGH- LOW) et vert (LOW-HIGH) mettent en lumière une incohérence locale où les résidus élevés ou faibles sont entourés de résidus opposés. Enfin, les zones non significatives (en gris) couvrant une grande partie de la région, suggère que pour ces zones, une distribution aléatoire des résidus.

3. Interpolation déterministe par l'inverse de la distance (IDW)

La carte présente les prévisions spatiales des précipitations journalières du mois de janvier 2100 obtenues par la méthode d'interpolation déterministe IDW. Les paramètres choisis pour la spatialisation sont : une

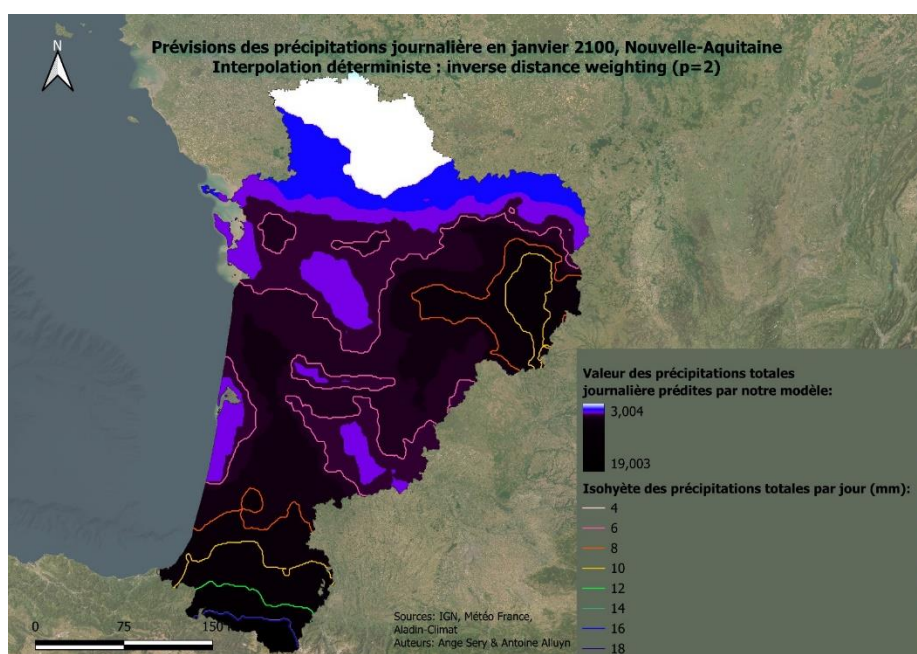


Figure 9 : Interpolation déterministe par la méthode de l'inverse de la distance (IDW).

favorise des conditions plus sèches. Les isohyètes révèlent des gradients distincts selon les zones géographiques. Dans les plaines centrales, les transitions des précipitations sont plus progressives traduisant une répartition homogène. En revanche, les zones de reliefs (particulièrement dans les Pyrénées) montrent des isohyètes plus resserrées, indiquant des variations rapides sur de courtes distances.

puissance fixé à 2 et un nombre de voisin minimum fixé à 5 et maximum fixé à 15. Nous remarquons que les précipitations les plus élevées (14 à 19 mm/ jour) se concentrent surtout dans le sud (près des Pyrénées) et l'est (près du Massif Central), où les mécanismes locaux tels que l'effet orographique amplifient les précipitations. Tandis que les précipitations les plus faibles (3 à 6 mm/ jour) se situent principalement dans les plaines du nord et les zones de basse altitude où l'absence de facteurs amplificateurs

1. Interpolation géostatistique par le krigeage universel

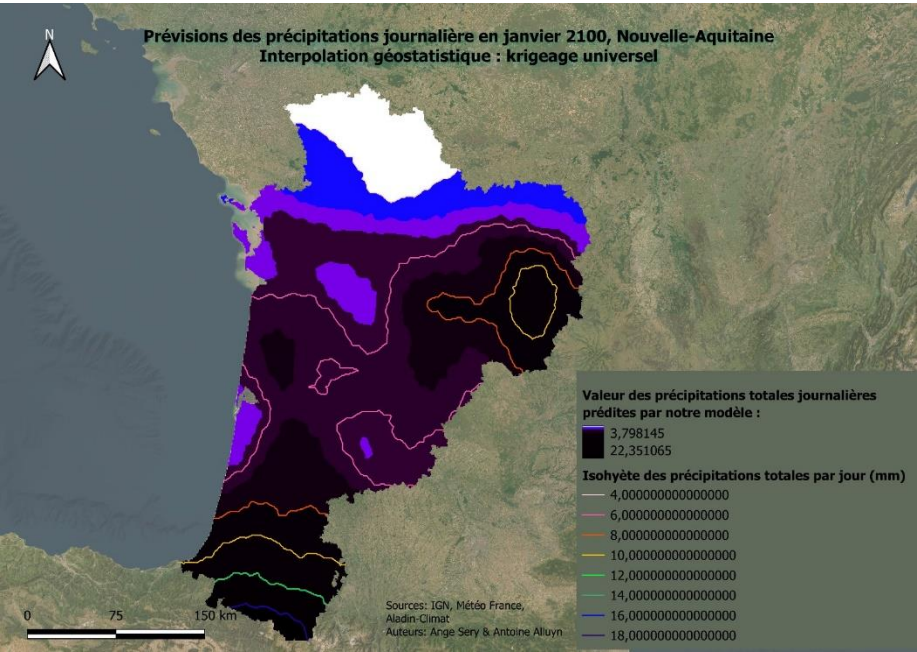


Figure 8 : Interpolation géostatistique par la méthode du Krigeage Universel.

La carte de l’interpolation spatiale par le Krigeage universel, montre des zones de faibles précipitations (3, 8 mm/ jour), particulièrement localisées dans le nord de la région, correspondant aux plaines et à des zones de basse altitude. A l’opposé, les précipitations les plus importantes (22 mm/ jour) se concentrent dans le sud et dans le nord-est, notamment dans les Pyrénées où des mécanismes orographiques intensifient les précipitations.

IV. Interprétation statistique et spatiale des résultats

L’objectif de notre travail était de comparer les différentes méthodes d’interpolation. Les résidus issus des validations croisés montrent des différences assez notables entre les modèles. On remarque des valeurs assez élevées d’erreur absolue dans le 9^{ème} décile pour nos trois modèles, mais particulièrement pour la régression linéaire. Cela indique que nos modèles ont du mal à prédire les très hautes valeurs de précipitations.

	Erreur moyenne absolue	Erreur médiane absolue	Erreur absolue du 9e décile	MSE	RMSE	R^2
Régression linéaire	0,906	0,677	1,923	1,499	1,224	0,780
Krigeage Universel	0,492	0,345	1,034	0,579	0,761	
IDW	0,320	0,196	0,68	0,291	0,539	

Figure 10 : Tableau des erreurs (résidus) des différentes méthodes d'interpolations.

L’IDW est globalement plus performante d’après toutes ces métriques d’erreur. On peut s’y attendre car c’est un modèle simple qui repose sur deux choses : la distance et le facteur de cette distance. Bien qu’il fournisse théoriquement le moins d’erreur de ces trois modèles, il n’en est pas autant le plus précis. On peut définir la précision autrement. Le modèle le plus précis serait celui qui prendrait le plus en compte les variables explicatives des précipitations.

Quand on augmente la complexité d’un modèle, on augmente aussi son imprécision mathématique mais les valeurs obtenues par un modèle complexes peuvent tout de même rendre mieux compte de la réelle répartition de la variable dépendante étudiée. Le krigeage est un modèle un peu plus complexe que l’IDW qui prend en compte la portée spatiale de l’autocorrélation des points mesurés ainsi que le plateau atteint par les valeurs

grâce à un covariogramme. D'après les performances de notre krigeage il apparaît ici comme un compromis performant. Enfin, notre régression linéaire présente des erreurs élevées pour les valeurs très élevées et une valeur de RMSE de 1,224, ce qui signifie que notre modèle sous-estime ou surestime en moyenne les précipitations de 1,224 mm par jour. Il possède un coefficient de détermination de 0,780, ce qui signifie que 22% de la variance n'est pas expliquée par notre modèle.

Sur la carte de prévisions des précipitations obtenue par régression linéaire on peut voir les « effets » de l'implémentation de nos deux variables explicatives :

- D'une part la latitude, qui possède une corrélation négative et qui s'observe ici avec un gradient nord-sud
- D'autre part l'altitude, qui possède une corrélation positive et qui s'observe ici à travers le contour des fonds de vallées fluviales qui se démarquent par des précipitations plus faibles.

Nous avons pu voir dans la littérature scientifique (Joly et *al.*, 2009) que des modèles bien plus complexes pouvaient être mis en place, notamment des régressions locales appliquées sur des polygones comprenant n stations de mesures. Cette méthode fournit de meilleurs résultats que les régressions globales (comme dans ce travail) et peuvent, par la multiplication des variables explicatives (pente, rugosité topographique, proximité d'une forêt, proximité de la mer) encore mieux expliquer la répartition d'une variable comme les précipitations.

Conclusion

Ce dossier a permis de spatialiser les projections relatives aux précipitations totales journalières en Nouvelle-Aquitaine à l'horizon 2100, en s'appuyant sur des méthodes d'interpolation déterministe, géostatistique et statistiques. L'intégration des variables explicatives telles que la latitude et l'altitude pour la méthode de régression linéaire a révélé des tendances importantes, notamment une forte corrélation entre ces facteurs et les précipitations observées.

L'utilisation de différentes techniques d'interpolation, telles que la pondération par l'inverse de la distance (IDW) et le krigeage universel, a permis de comparer la méthode de régression linéaire à celles-ci et de valider les résultats obtenus par une approche méthodologique rigoureuse. L'IDW a démontré son efficacité dans la modélisation spatiale des précipitations à travers ces métriques d'erreur, plutôt faible par rapport aux deux autres méthodes d'interpolations.

Les résultats obtenus soulignent une forte variabilité spatiale des précipitations, avec des valeurs particulièrement élevées dans certaines zones du territoire, correspondant généralement à des altitudes élevées ou des latitudes spécifiques. Cependant, des limites méthodologiques ont été identifiées, notamment une performance moindre des modèles sur les extrêmes des valeurs de précipitations.

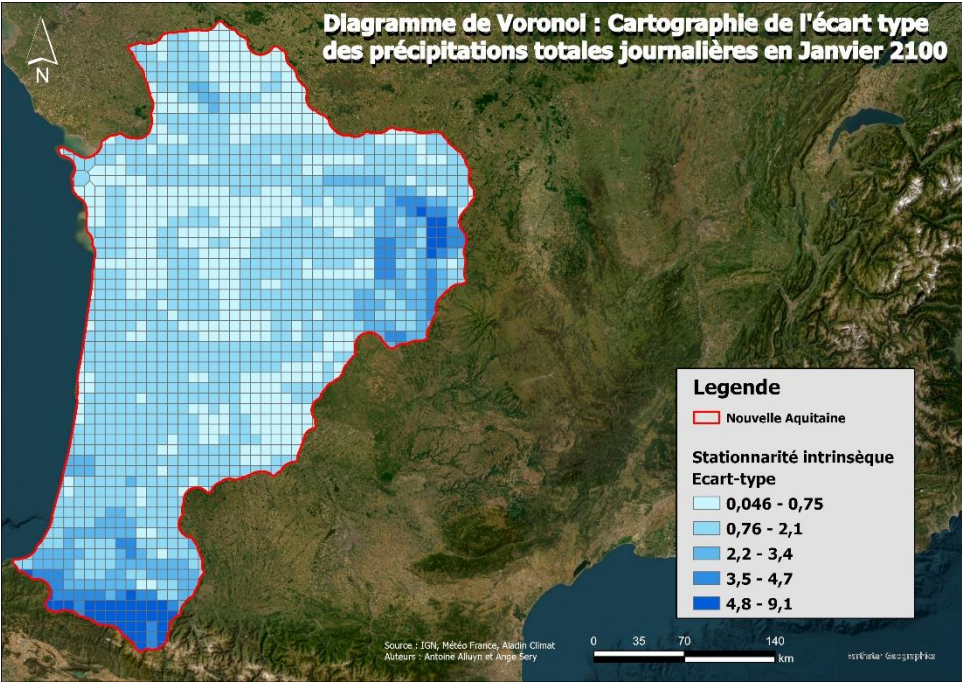
Ce travail contribue à une meilleure compréhension des impacts climatiques à venir sur une région particulièrement exposée. Il offre également un outil précieux pour l'aide à la décision dans la gestion des ressources en eau et l'adaptation au changement climatique.

Bibliographie

- Gratton Y., 2014, Le krigeage : la méthode optimale d'interpolation spatiale, p. 5. Repéré à [Le krigeage : la méthode optimale d'interpolation spatiale](#)
- Joly D., Thierry B., Cardot H., Cavailhès J., Hilal M. et Wavresky P., 2009, Interpolation par régressions locales : application aux précipitations en France : *L'Espace géographique*, Vol. 38(2), p. 157-170. DOI : [10.3917/eg.382.0157](#)
- Laala A. et Alatou D., 2017, Interpolation spatiale des températures mensuelles en Algérie orientale, *La Météorologie*, (98), p. 45. DOI : [10.4267/2042/62459](#)
- Météo France, 2020, *Bilan climatique de l'année 2020 sur la France métropolitaine*. France Métropolitaine. Repéré à <https://meteofrance.fr/actualite/publications/les-publications-de-meteo-france/publications/2020-les-bilans-climatiques>
- Nalder I. A. et Wein R. W., 1998, Spatial interpolation of climatic Normals: test of a new method in the Canadian boreal forest, *Agricultural and Forest Meteorology*, 92(4), p. 211-225. DOI : [10.1016/S0168-1923\(98\)00102-6](#)
- Rubel F. et Kottek M., 2010, Observed and projected climate shifts 1901-2100 depicted by world maps of the Köppen-Geiger climate classification, *Meteorologische Zeitschrift*, 19(2), p. 135-141. DOI : [10.1127/0941-2948/2010/0430](#)
- Tobler W. R., 1970, A Computer Movie Simulating Urban Growth in the Detroit Region, *Economic Geography*, 46, p. 234. DOI : [10.2307/143141](#)

Annexe

Annexe 1 : Diagramme de Voronoi : cartographie de l'écart-type.



Annexe 2 : Diagramme de Voronoi : cartographie de la moyenne.

