

UNIVERSITÉ DE STRASBOURG – Faculté de géographie et d'aménagement

RAPPORT TRAITEMENTS D'IMAGES NIVEAU 1

Master 1 Géomatique : Observation de la Terre et Géomatique

Comparaison de la classification par approches objet et pixel d'une image pléiades à très haute résolution en milieu urbain

SERY Ange



Année Universitaire : 2024 - 2025

Professeur : M. GARDOT Félix

Table des matières

Table des matières.....	2
Introduction	3
I. Données.....	5
1. Présentation de l'image multispectrale pléiades	5
2. Donnée de référence OCSGE.....	5
II. Méthodologie.....	6
1. Définition des classes d'occupation du sol.....	6
2. Sélection des données d'entrainements et de validations.....	7
3. Entrainement du modèle	7
4. Application du modèle et validation	9
5. Protocole de test.....	9
6. Comparaison avec la donnée de référence OCSGE2.....	12
7. Schéma méthodologique	13
III. Résultats	14
1. Classification ‘Objet’	14
2. Classification ‘Pixel’	20
3. Comparaison de la classification ‘pixel’ et de la classification ‘objet’	24
4. Comparaison de nos classifications avec la donnée de référence	26
IV. Discussion.....	27
Conclusion	28
Bibliographie	30
Annexe.....	32

Introduction

La cartographie de l'occupation du sol joue un rôle crucial dans la gestion durable des ressources naturelles, l'aménagement du territoire et la surveillance environnementale. Les progrès en télédétection, notamment grâce aux images à très haute résolution (THR) comme Pléiades, offrent de nouvelles opportunités pour une classification précise de l'occupation du sol. L'occupation du sol (OCS) est définie comme la couverture physique de la surface terrestre (à l'état naturel ou transformé) et se traduit par type d'usage qu'en fait l'Homme (Géoconfluence, 2017). En effet, l'utilisation des sols dépend effectivement d'un ensemble de variables géographiques, sociale et économiques. En France, des campagnes régulières de suivi de l'OCS sont menées, ce qui permet de mieux connaître et suivre l'évolution du territoire (DataGrandEst, 2021).

A l'échelle Européenne, la directive INSPIRE encourage cette dynamique d'acquisition de données géographique (Beaumont et al., 2017). Cependant, le traitement de ces données nécessite des ressources financières et humaines considérables, ce qui rend l'automatisation des tâches essentiels. Dans le domaine de l'imagerie satellitaire et d'autres domaines, le développement de modèles d'apprentissage automatique repose sur l'utilisation de données de référence pour générer de nouvelles connaissances (Judge, 2019). La base de données OCSGE, avec une précision sémantique et plusieurs échelles, suit ce modèle et en est un parfait exemple.

Les images multispectrales (Figure 1) de Pléiades, offrent une résolution spatiale de 50 cm et quatre bandes spectrales (B0 : rouge, B1 : vert, B2 : bleu et B3 : proche infrarouge), permettant une distinction fine des différentes classes d'occupation du sol. De plus, l'ajout d'attributs exogènes à ces images permettent d'exploiter le lien existant entre les caractéristiques des surfaces observées et leur signature spectrale, afin d'obtenir une très bonne classification de l'occupation des sols.

Les techniques de classification visent à regrouper des zones d'une image qui affichent des réponses spectrales similaires au sein d'une même catégories. Plusieurs chercheurs, ont eu à utiliser des méthodes de classification pour créer des cartes d'occupation du sol à partir d'une image multispectrale. Les méthodes de classification supervisée utilisent des algorithmes (comme le maximum de vraisemblance, Randon Forest, K-plus proches voisins, etc.) pour identifier les différentes classes d'occupation du sol présentes dans l'images (telles que l'eau, les zones urbaines, la végétation, les sols nus, etc.), ces classes ayant été définies au préalable par l'utilisateur (Rodriguez-Galiano et al., 2012). Cette méthode nécessite la mise en place d'une base de données d'apprentissages pour chaque classe à cartographier avant d'effectuer la classification. Les méthodes de classification non supervisées (p. ex. algorithme k-means) sont des processus plus automatisés ne nécessitant pas de connaissance à priori des classes (Duda et Canty, 2002). Dans les deux cas, il est essentiel et recommander de collecter des données de validations sur le terrain pour évaluer la précision du modèle et/ ou du classifieur utilisé (Teillet et al., 2022 ; Regniers, 2014).

Les attributs exogènes sont des variables supplémentaires, calculées dans la plupart des cas à partir des bandes spectrales de l'image de base, et ayant pour but d'améliorer la classification. Parmi ces attributs, nous

avons les indices spectraux qui exploitent la combinaison des bandes de l'image multispectrale pour mettre en évidence mes propriétés biophysique des surfaces imagées. Par exemple, pour mettre en évidence les zones en végétation d'une images multispectrales, l'on utilisera les indices de végétation (comme le NDVI, *Normalized Difference Vegetation Index*) basé sur les valeurs de réflectance dans le proche infrarouge (PIR) et le rouge (R). Pour les zones d'eau, dont la signature spectrale révèle des valeurs de réflectance décroissantes depuis des longueurs d'onde du domaine du bleu vers l'infrarouge, le calcul de l'indice (NDWI, *Normalized Difference Water Index*) sera basé sur les valeurs de réflectance dans le domaine du vert (V) et le proche infrarouge (PIR).

Il existe aussi des indices texturaux (comme l'entropie, la dissimilarité), utilisés en complémentarité avec les informations spectrales pour décrire une image en la décomposant en fréquences et orientations (Teillet et al., 2022). Les indices texturaux ont largement été utilisés pour le traitement et l'extraction d'information des images satellites, en particulier dans des études sur les milieux forestiers et urbains (Puissant et al., 2006, 2014 ; Regniers, 2014 ; Proisy et al., 2007).

Dans cette étude, nous nous pencherons sur deux méthodes : l'approche pixel, où chacun des pixels de l'image est considéré comme une unité individuelle, et sur l'approche objet, où les pixels sont regroupés en groupes cohérents en fonction de critères spatiaux, spectraux et contextuels. Chacune des deux méthodes sera testée, analysée et comparée. Un protocole de test basé sur l'apport d'attributs exogènes dans la classification sera aussi développé.

Nous effectuerons nos travaux à partir d'une image Pléiade de résolution 50cm et de 1 km². La zone d'étude se trouve au Centre-Ouest de l'Eurométropole de Strasbourg. On y retrouve majoritairement un bâti discontinu peu dense, ponctué d'espaces ouverts. Ainsi, nous nous demanderons « Quelle méthode permet au mieux de classifier l'occupation du sol en milieu urbain peu dense ? Comparaison entre l'approche pixel et objet ».

I. Données

1. Présentation de l'image multispectrale pléiades

Le site d'étude se situe au Centre-Ouest de l'Eurométropole de Strasbourg (Nord-Est de la France). C'est une image multispectrale pléiades à très haute résolution acquise en juin¹ 2021 et téléchargée sur la plateforme 'Earth Online'. L'image se compose de quatre bandes multispectrales (B0 : 620-700 nm [Rouge], B1 : 510-590 nm [Vert], B2 : 450-530 nm [Bleu], B3 : 775-915 nm [PIR]) à une résolution spatiale de 0,5. Il couvre une superficie de 1 km² (Figure 1). Le site est caractérisé par un bâti urbain discontinu peu dense, ponctué d'espaces ouverts (forêts et cultures). Au nord et au sud-ouest, on retrouve des surfaces de cultures, pour certaines nues et pour d'autres faiblement enherbées. Des ripisylves sont également présents le long d'un cours d'eau au sud-ouest, et des forêts au nord-ouest.

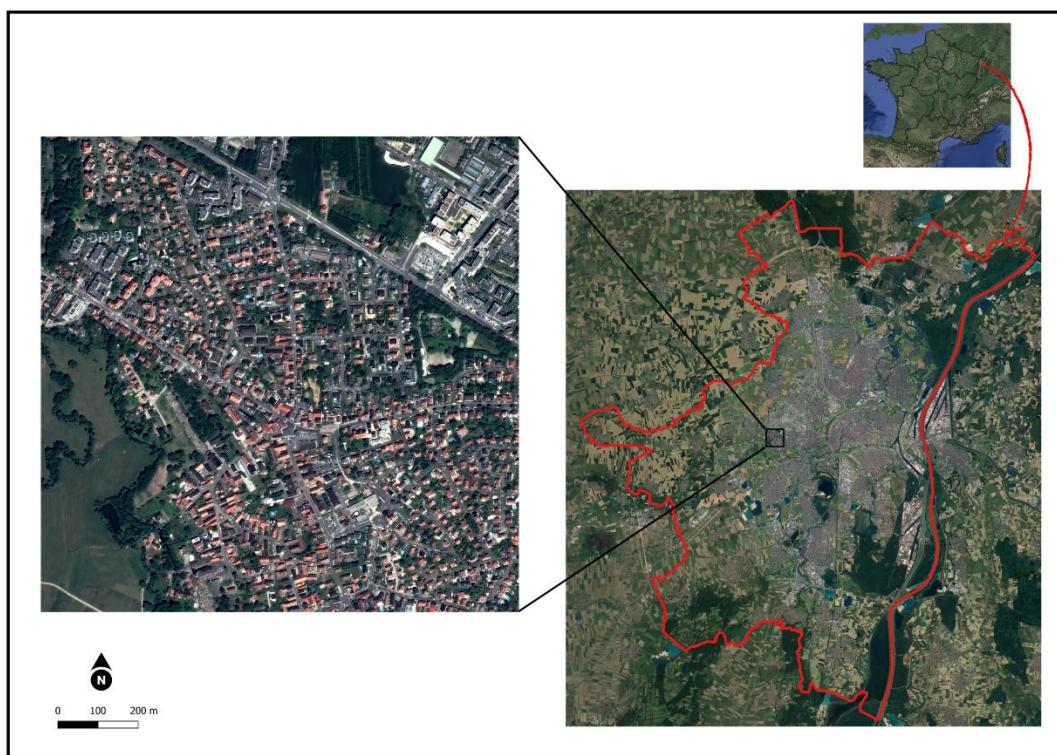


Figure 1 : Localisation du site d'étude. SERY Ange, 2024

2. Donnée de référence OCSGE

La donnée de référence que nous avons utilisée pour comparer à nos résultats de classification est l'OCSGE. C'est une carte d'occupation du sol qui couvre la région du Grand-EST. Elle est sous plusieurs formes (raster, shapefile, geopackage, etc.). Cette carte d'occupation a plusieurs niveaux de classification, allant du niveau 1 (petite échelle) au niveau 4 (petite échelle). Il existe encore d'autres niveaux mais sont plus spécifique en termes d'occupation du sol. La donnée a été téléchargée sur la plateforme 'DataGrand-Est' sous le format shapefile.

¹ Date inventée, vu que la date d'acquisition n'a pas été donnée dans les consignes.

Nous avons choisi cette donnée de référence car elle a une bonne précision géométrique et sémantique et ses niveaux de classification correspondaient le mieux à l'occupation du sol de notre image.

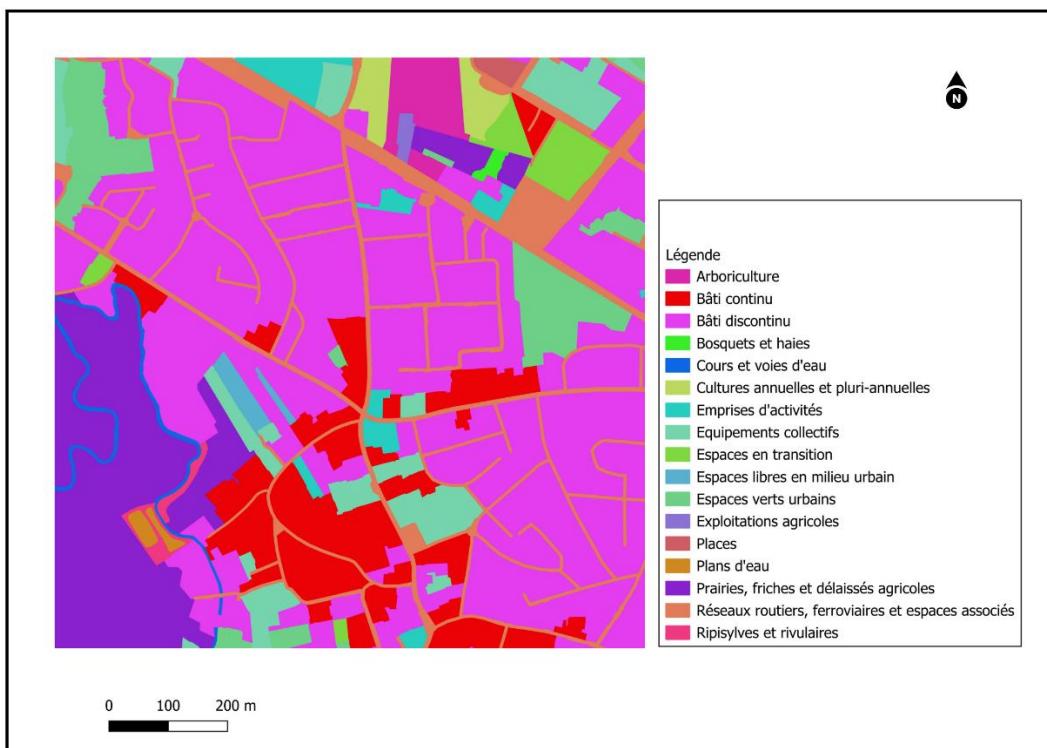


Figure 2 : Donnée de référence, OCSGE2-GrandEst. Niveau 3 de classification. Source : DataGrandEst.

II. Méthodologie

1. Définition des classes d'occupation du sol

La démarche suivie pour la classification comporte plusieurs étapes initialisées par une définition des classes d'occupation du sol que l'on souhaite rechercher dans l'image. Le choix des classes s'est fait sur la base de l'interprétation visuelle de notre image en vrai couleur (R : B0, V : B1, B : B2). La nomenclature adoptée trouve sa source dans la carte d'occupation du sol OCSGE2 – GrandEst.

En effet, on distingue une classe « **Bâtiment** » (1) correspondant au bâti continu, discontinu, équipements collectifs. Deux classes relevant de la végétation naturelle ont été séparées en : « **Végétation haute** » (4) et « **Végétation basse** » (5). Toute formation végétale composée d'arbres mais aussi d'arbustes et de buissons a été répertoriée sous le thème de végétation haute. La végétation basse correspond aux surfaces agricoles, de prairie, plantes herbacées. La classe « **Sol nu (sable)** » (3) correspond aux surfaces non végétalisées marqué par une teinte brune sur l'image. Cette classe est plus localisée dans les espaces verts urbains. Une classe « **Routes** » (2) a été créée et comprend les réseaux routiers, ferroviaire (tramway) et les espaces associés (parking). La dernière classe est « **Eau** » (6) et correspond aux plans d'eau et cours d'eau.

2. Sélection des données d'entrainements et de validations

La classification supervisée consiste à diviser l'espace spectral en différentes classes à l'aide des sites d'entraînement et de validation. Cette étape peut être manuelle (digitalisation) ou semi-automatique (sélection d'une donnée de référence d'occupation des sols) (Puissant et al., 2014). Dans certains cas d'étude, les sites d'entraînement jouent le rôle d'entraîneur et validateur. En effet, il est divisé en un ratio ['entraînement' : 'validation'], dont le plus grand ratio correspond aux données d'entraînement et le plus petit ratio aux données de validation. Dans notre cas, étant donné que la classification objet moyennant l'algorithme Random Forest permet la sélection d'objets échantillons issus de la segmentation préalable de l'image, pour chacune des classes d'occupation du sol, nous avons procédé au choix des sites d'entraînement et de validation sur l'image segmentée. Cependant, nous nous sommes assurés à ce que les données d'entraînements ne correspondent pas aux données de validation dans la logique d'éviter des biais dans la classification.

Un total de 117 polygones d'entraînements a été sélectionnés, dont 23 correspondaient à la classe (1), 24 pour la classe (2), 9 pour la classe (3), 32 pour la classe (4), 21 pour la classe (5) et 7 pour la classe (6). Pour les données de contrôle, un total de 44 polygones a été sélectionné dont 13 pour la classe (1), 12 pour la classe (2), 3 pour la classe (3), 11 pour la classe (4), 7 pour la classe (5) et 3 pour la classe (6).

Pour la classification orientée 'pixel', nous avons utilisé les données d'entraînement issues de la classification objet. Pour cela, nous avons regrouper par catégorie toutes les classes (117 au total) afin d'obtenir que 6 classes.

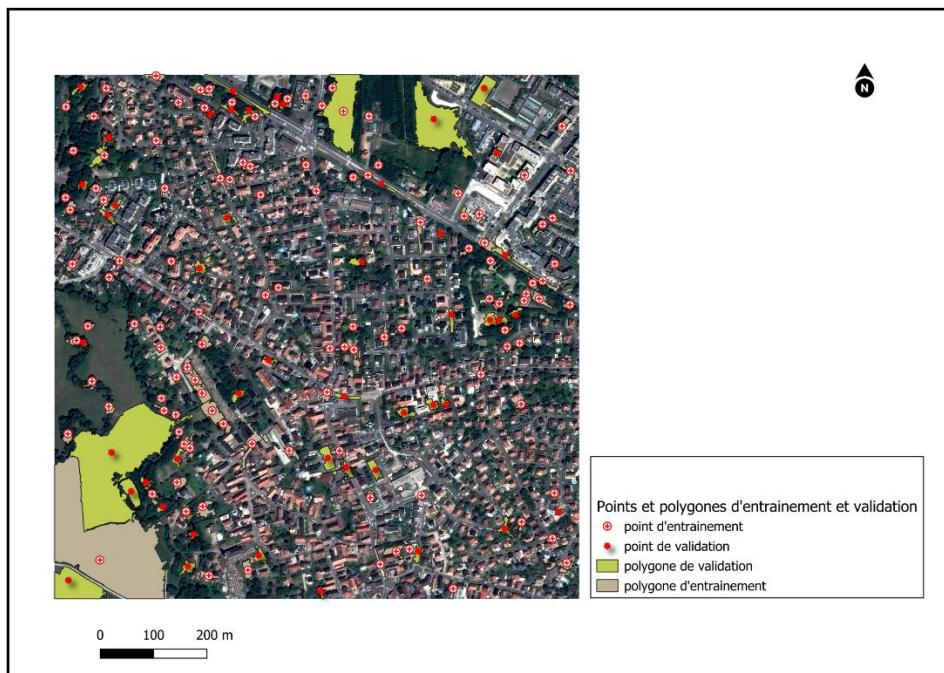


Figure 3 : Localisation des polygones d'entraînements et de validation. SERY Ange, 2024

3. Entrainement du modèle

3.1. Classification orienté 'Objet'

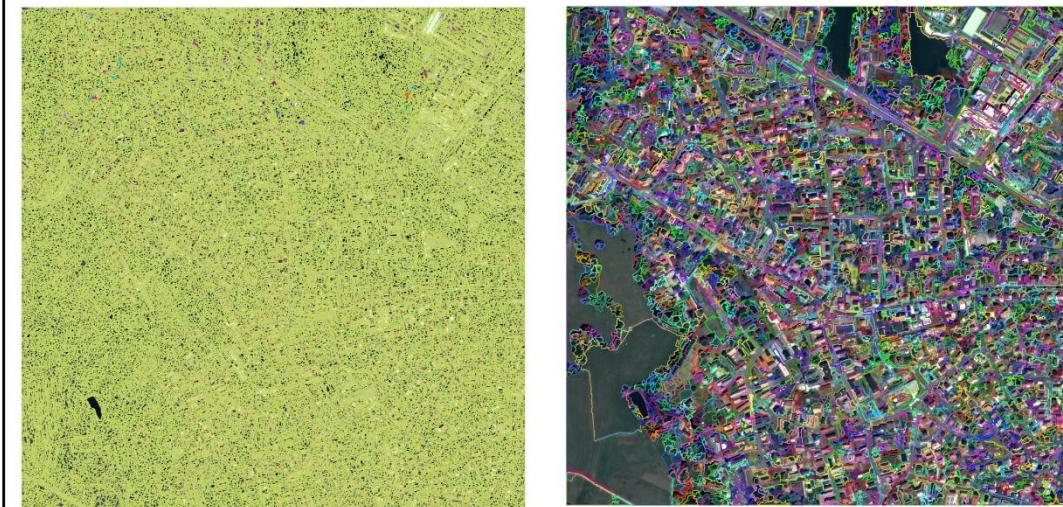
Cette étape consiste à entraîner l'algorithme de classification à partir des données d'entraînement. Différentes méthodes peuvent être utilisées pour cette étape. Notamment les algorithmes de classification basés sur les

statistiques, les réseaux de neurones ou encore les machines vectrices de support. Nous avons utilisé le Random Forest comme modèle d'entraînement. En effet, l'algorithme Random Forest est un modèle non paramétrique d'apprentissage automatique qui génère plusieurs arbres de décision en utilisant un sous-ensemble d'échantillons et de variables (Breiman L., 2001).

Dans le cadre de cette étude, l'entraînement du modèle par l'algorithme *Randon Forest* a été fait à partir du plugin Orfeo Tool Box (OTB) de Qgis (Version 3.38). Les paramètres utilisés sont principalement ceux par défaut proposés par l'outil '*TrainVectorClassifier*' de l'OTB.

Cependant, avant d'entrainer le modèle, nous avons segmenté l'image pléiades. Comme annoncé dans la partie 2.), cette étape nous a permis de sélectionner nos données d'entraînement et de validation. Elle constitue une étape importante et méthodologiquement déterminante. Pour ce travail, elle a été effectuée sous OTB en utilisant l'algorithme 'LargeScaleMeanShift'. Cet algorithme de segmentation ne repose pas seulement sur les valeurs de pixels individuels, mais aussi sur le voisinage du pixel (texture, forme, topologie) (Bengoufa et al., 2021). Deux paramètres importants, à savoir les paramètres de rayon spatial (*Spatial Radius*) et la gamme de rayons (*Range Radius*) sont intégrés dans l'OTB et fixés par l'utilisateur. Par railleur, il est conseillé de fixer ces paramètres à travers des essais expérimentaux. Selon Regniers (2014), le choix des paramètres n'est pas critique et une image sur-segmentée n'a pas de conséquences dramatique (sauf le nombre plus élevé de région à classifier) tant qu'ils permettent d'aboutir à une image suffisamment segmentée pour éviter la création de région contenant des valeurs de pixels « mixtes ».

Les deux exemples de résultats de segmentation présentés à la Figure 4 ont été obtenu avec des paramètres



différents, mais devraient permettre d'aboutir à la même classification selon Regniers (2014).

Figure 4 : Exemple de résultats de segmentation obtenus par l'algorithme *LargeScaleMeanShift*. Les lignes désignent les contours des régions. A gauche : *Spatial Radius* = 5, *Range Radius* = 15, *Minimum segment size* = 50. A droite : *Spatial Radius* = 5, *Range Radius* = 100, *Minimum segment size* = 500.

Dans un souci d'optimisation des traitements et de plus de lisibilité, nous avons choisi la segmentation de droite.

Ensuite, pour chaque segment (objet) une moyenne et écart type ont été calculés sur chaque bandes spectrale par des statistiques sous OTB. Ces statistiques ont servi à l'entraînement et l'application du modèle.

3.2. Classification orienté ‘Pixel’

Pour la classification pixel, l’entraînement du modèle a été effectué à partir du plugin OTB via l’outil ‘*TrainImageClassifier*’, en utilisant les mêmes paramètres que pour la classification objet. Le seul point qui a changé, c’est que nous avons utilisé en entrée uniquement les données d’entrainements, que nous avons regroupé par catégorie avant.

4. Application du modèle et validation

4.1. Classification orienté ‘Objet’

Une fois le modèle entraîné, il peut classer l’ensemble de l’image en assignant chaque région de pixel à une classe selon sa proximité avec les régions d’entraînement. L’outil que nous avons utilisé pour l’application de nos modèles est le ‘*VectorClassifier*’ de OTB. Nous mettons en entrée, la segmentation de l’image et le modèle entraîné, tout en cochant les statistiques calculés lors de la segmentation (moyenne et écart-type). Nous obtenons en sortie une couche vecteur résultante de la classification que nous convertissons en raster, tout en gardant la même résolution spatiale que l’image pléiades. Enfin, une évaluation de la précision de la classification est réalisée d’une part par approche statistique (métriques tels que : précision, rappel, F-score, précision globale) et d’autre part d’une approche visuelle.

4.2. Classification orienté ‘Pixel’

L’application du modèle a également été réalisée avec OTB via l’outil ‘*ImageClassifier*’. En entrée, nous utilisons l’image pléiade et le modèle entraîné par l’algorithme Random Forest. En sortie, nous obtenons une image classifiée en 6 classes au format raster. La précision de la classification est évaluée également par approches statistiques et visuelles.

5. Protocole de test

La mise en place d’un protocole de test permet d’évaluer l’apport des indices endogènes dans la classification. Dans notre cas d’étude, nous nous focaliserons sur les indices spectraux et texturaux², dérivés de notre image pléiades et du Modèle Numérique d’Elévation (MNE), qui permet de mettre en évidence les zones bâties et un masque pour la végétation haute. Les indices spectraux comprennent l’indice de végétation (NDVI) (Figure 5.A), l’indice d’eau à différence normalisée (NDWI) (Figure 5.B). Les indices texturaux incluent l’entropie (Figure 5.C) et la dissimilarité³ (Figure 5.D). Pour ce protocole de test, nous avons formulé plusieurs hypothèses selon lesquels l’ajout d’un ou plusieurs attributs exogènes améliorerait la classification, donc la bonne distinction des classes. C’est la raison pour laquelle nous n’avons pas ajouté de classe supplémentaire dans le protocole de test.

² En télédétection, la texture est définie comme l’ensemble des relations en niveau de teinte entre points élémentaires voisins dans une image (Dedieu et al., 1997).

³ L’entropie et la dissimilarité sont des indices de la matrice de cooccurrence, développé par Haralick. L’entropie présente des valeurs faibles si on a dans l’image plusieurs mêmes couple de pixels. C’est un indicateur de désordre.

Il faut préciser que le masque mettant en évidence la végétation haute ainsi que le MNE nous ont été fourni par le professeur. De ce fait, certains pixels appartenant au masque ‘végétation’ avaient des valeurs égales à 0. Nous avons donc remplacé ces valeurs par -9999 dans le but d’éviter des erreurs dans la classification.

N.B. Le même protocole test a été appliqué pour les deux méthodes de classifications dans l’objectif de comparer les résultats.

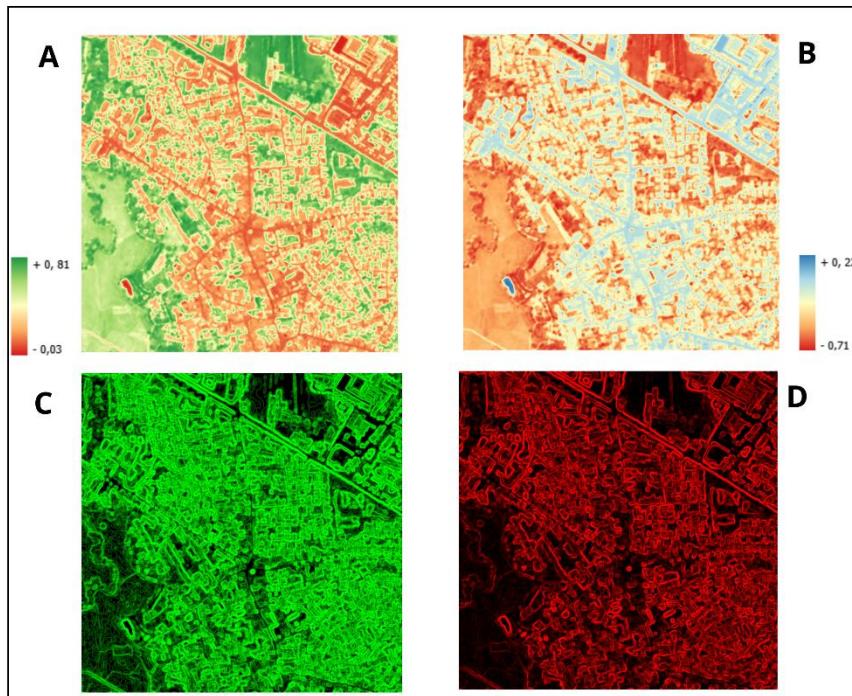


Figure 5 : Indice spectraux et texturaux calculés sur la base de l'image pléiade. La dissimilarité (D) et l'entropie (C) ont été calculé sur la base du NDVI et sur le logiciel SNAP

Les différents tests que nous avons appliqués ainsi que les hypothèses correspondantes sont présentées dans le tableau suivant :

Classes	Attributs	Algorithmes	Hypothèses
<u>Test 1</u> : 4 classes thématiques - Bâtiments - Routes - Sol nu - Végétation haute - Végétation basse - Eau	Rouge + Vert + Bleu + PIR + NDVI	K-Nearest Neighbors (<i>number of neighbors</i> : 32)	L'apport du NDVI faciliterait la distinction entre la végétation basse, la végétation haute et les autres classes.
<u>Test 2</u> : 4 classes thématiques - Bâtiments - Routes - Sol nu		K-Nearest Neighbors (<i>number of</i>	L'apport du NDWI améliorerait la distinction entre la surface

- Végétation haute - Végétation basse - Eau	Rouge + Vert + Bleu + PIR + NDWI	<i>neighbors :</i> 32)	d'eau et les zones d'ombres dans l'image.
<u>Test 3 : 4 classes thématiques</u> - Bâtiments - Routes - Sol nu - Végétation haute - Végétation basse - Eau	Rouge + Vert + Bleu + PIR + NDVI + Végétation	K-Nearest <i>Neighbors</i> (number of <i>neighbors :</i> 32)	L'apport du NDVI et de l'image binaire 'végétation' améliorerait la distinction entre la végétation basse et la végétation haute.
<u>Test 4 : 4 classes thématiques</u> - Bâtiments - Routes - Sol nu - Végétation haute - Végétation basse - Eau	Rouge + Vert + Bleu + PIR + MNE	K-Nearest <i>Neighbors</i> (number of <i>neighbors :</i> 32)	L'apport du MNE faciliterait le classement des zones bâties.
<u>Test 5 : 4 classes thématiques</u> - Bâtiments - Routes - Sol nu - Végétation haute - Végétation basse - Eau	Rouge + Vert + Bleu + PIR + Dissimilarité	K-Nearest <i>Neighbors</i> (number of <i>neighbors :</i> 32)	L'apport de la Dissimilarité faciliterait la catégorisation des zones bâties et des bosquets (assimilé à la végétation haute).
<u>Test 6 : 4 classes thématiques</u> - Bâtiments - Routes - Sol nu - Végétation haute - Végétation basse - Eau	Rouge + Vert + Bleu + PIR + Entropie	K-Nearest <i>Neighbors</i> (number of <i>neighbors :</i> 32)	L'apport de l'Entropie faciliterait la distinction de la classe 'bâtiments' par rapport aux autres classes.
<u>Test 7 : 4 classes thématiques</u> - Bâtiments - Routes - Sol nu - Végétation haute	Rouge + Vert + Bleu + PIR + Dissimilarité + Entropie	K-Nearest <i>Neighbors</i> (number of	L'apport de la Dissimilarité et de l'Entropie permettrait de bien

- Végétation basse		neighbors : 32)	categoriser l'ensemble des classes.
- Eau			

Test 8 : 4 classes thématiques		K-Nearest Neighbors (number of neighbors : 32)	L'apport du NDVI, NDWI, de la Végétation, du MNE, de la Dissimilarité et de l'Entropie permettrait une classification efficace de l'ensemble des classes.
- Bâtiments	Rouge + Vert + Bleu + PIR + NDVI + NDWI + Végétation + MNE + Dissimilarité + Entropie		
- Routes			
- Sol nu			
- Végétation haute			
- Végétation basse			
- Eau			

Après avoir identifié nos différents tests d'hypothèses, nous avons entraîné de nouveau le modèle de classification correspondant à chaque test. Les modèles ont été entraînés de la même manière que les deux premières classifications (sans apport d'indices exogènes) et avec les mêmes paramètres. Nous avons simplement ajusté les entrées (stacks) en fonction des tests. Enfin, nous avons analysé les performances de chaque classe (avec les métriques de rappel, précision et F-Score), ainsi que la performance globale (F1-Score moyen) de chaque modèle.

6. Comparaison avec la donnée de référence OCSGE2

D'abord, pour obtenir un certain nombre de classes étiquetées, adaptées à notre image Pléiades, nous avons conservé la classification de niveau 3. Ensuite, nous avons fait une reclassification sémantique (Figure 6) afin de réduire la complexité de la typologie et qui est adapté à nos classes d'occupation du sol. Enfin, nous avons appliqué une rastérisation de la couche shape avec une résolution de 0,5 m.

La comparaison a été réalisée visuellement plutôt que statistiquement, car nous n'avons pas pu établir de correspondance pour la classe « Sol nu » dans la donnée de référence. Par conséquent, une différence entre les deux images n'était pas possible en raison du nombre inégal de classes.

Typologie d'origine	Nouvelle typologie
Places	Bâtiments
Bâti continu	
Bâti discontinu	
Emprise d'activités	
Espèces en transition	
Equipements collectifs	
Réseaux routiers, ferroviaires et	Routes
Arboricultures	Végétation basse
Exploitations agricoles	
Cultures annuelles et pluri-annuelles	
Prairies, friches et délaissées agricoles	
Bosquets et haies	Végétation haute
Ripisyles et rivulaires	
Espaces vert urbains	
Espaces libre en milieu urbain	
Plan d'eau	Eau
Cours et voies d'eau	

Figure 6 : Reclassification de la donnée de référence.

7. Schéma méthodologique

Pour rendre plus efficace les traitements et gagné du temps, nous avons élaboré un ‘Modeleur’ pour chaque méthode de classification sous Qgis (Annexe 1et 2). Le modeleur est basé sur les étapes que nous avons présenté précédemment.

7.1. Schéma méthodologique de la classification ‘Objet’

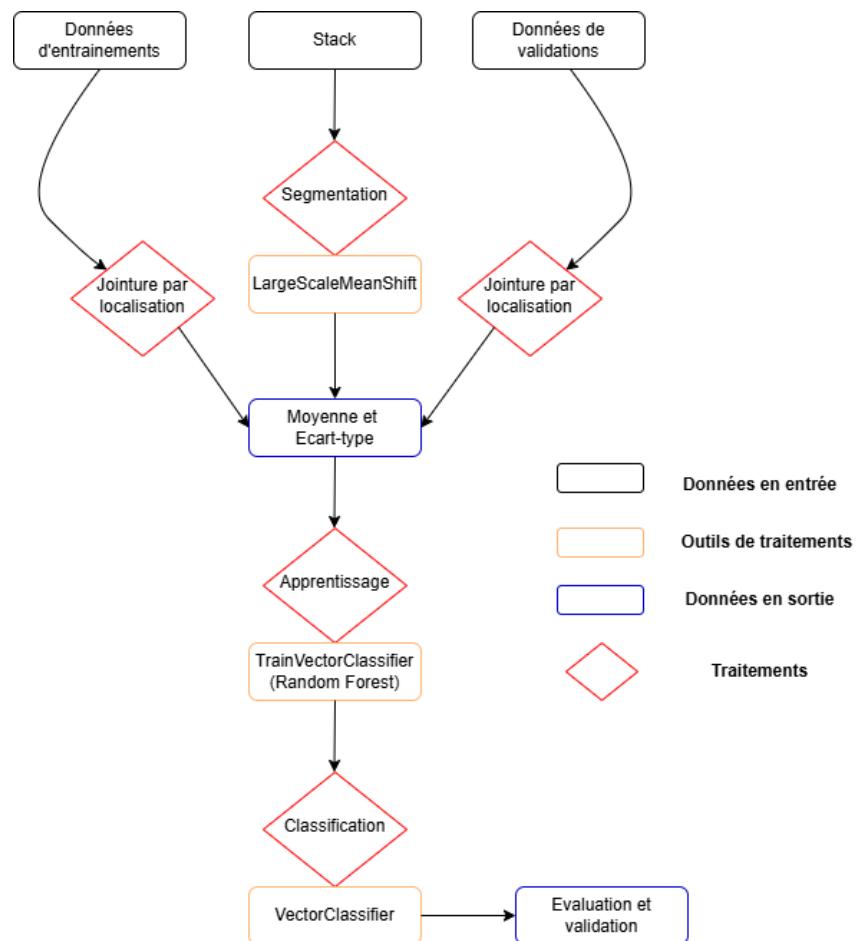


Figure 7 : Méthodologie de classification objets. SERY Ange, 2024

7.2. Schéma méthodologique de la classification ‘Pixel’

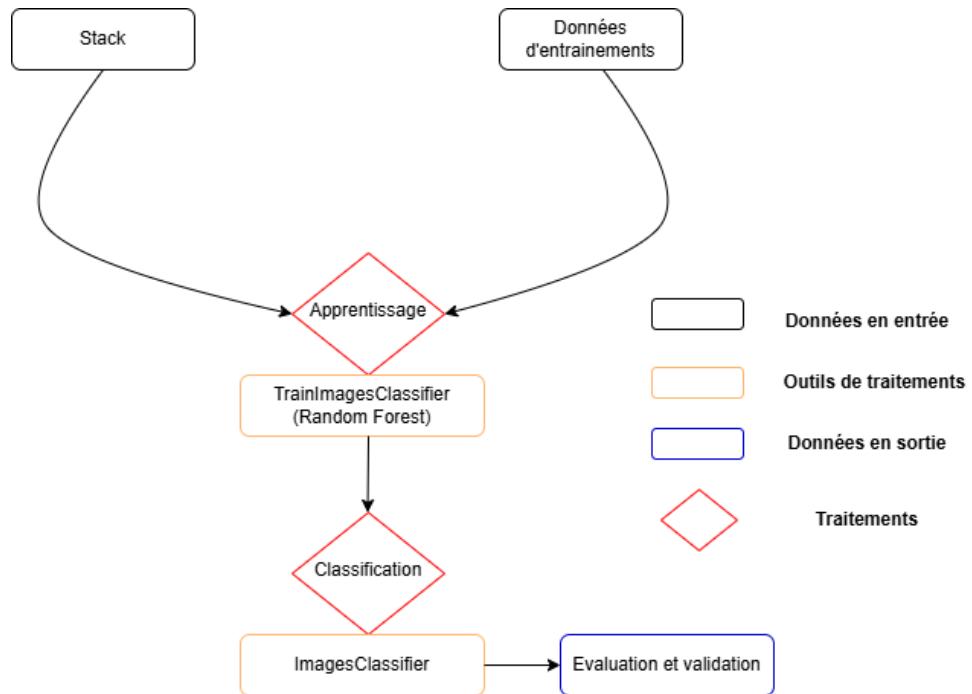


Figure 8 : Méthodologie de la classification pixel. SERY Ange, 2024

III. Résultats

1. Classification ‘Objet’

1.1. Evaluation du modèle

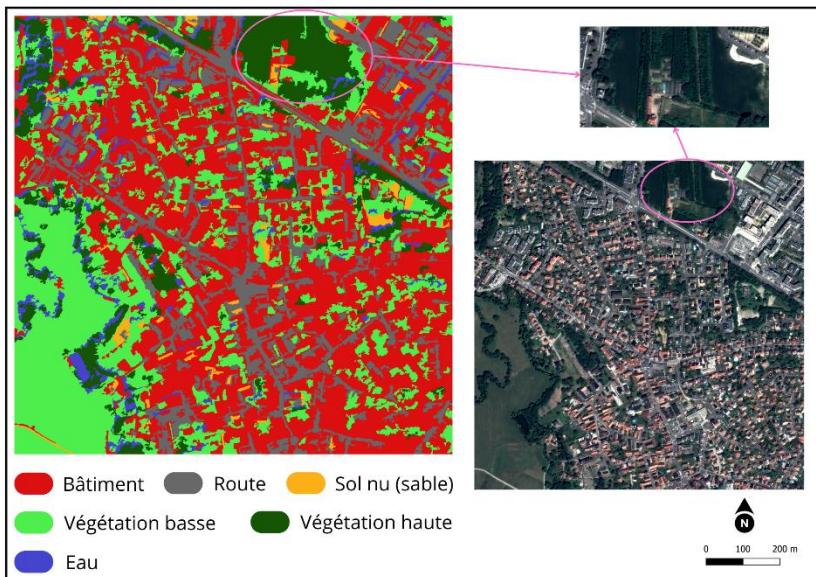


Figure 9 : classification objet de l'image pléiades.

La figure ci-dessous est le résultat de la classification appliquée à l'image pléiades sans apport d'indice exogènes. On observe au nord-est de l'image qu'une grande surface agricole, initialement classée comme « Végétation basse », a été confondue avec la « Végétation haute ». Les bâtiments semblent bien classés, bien qu'ils soient regroupés en patchs, ce qui a supprimé certains tronçons de route entre les quartiers. De plus, la catégorie « Eau » a été confondue avec des zones sombres ou ombragées, ce qui a entraîné la présence d'étendues d'eau là où il ne devrait pas en avoir.

des zones sombres ou ombragées, ce qui a entraîné la présence d'étendues d'eau là où il ne devrait pas en avoir.

Toutefois, cette appréciation visuelle ne permet pas d'évaluer la précision de la classification, ce que nous pouvons analyser à travers la matrice de confusion (Figure 10). La matrice de confusion permet de visualiser le nombre de prédictions correctes et incorrectes faites par le modèle pour chaque classe. La précision mesure la proportion de vrais positifs, c'est-à-dire le rapport des vrais positifs sur la somme des vrais positifs et des faux positifs. Le rappel, quant à lui, mesure la proportion de vrais positifs que le modèle a réussi à identifier parmi tous les exemples réellement positifs (Sparfel L., 2018). Le F-score est une mesure de performance combinant rappel et précision. Ce tableau affiche en diagonale, le nombre de pixels objets bien classés et hors diagonale, le nombre de pixels objets mal classés.

		REFERENCE						
PREDICTION		Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	Rappel
	Bâtiment	8	4	0	0	1	0	0,62
	Routes	2	10	0	0	0	0	0,83
	Sol nu (sable)	0	1	2	0	0	0	0,67
	Végétation haute	0	0	0	11	0	0	1,00
	végétation basse	0	0	0	2	6	0	0,75
	Eau	0	0	0	0	0	3	1,00
Précision		0,80	0,67	1,00	0,85	0,86	1,00	
Classe	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau		
F-score	0,70	0,74	0,80	0,92	0,80	1,00		
Mean F-score	0,83							

Figure 10 : Matrice de confusion de la classification objet de l'image pléiades.

En analysant la précision, le rappel et le F-scores des classes, on remarque que :

- La classe « Eau » et la classe « Végétation haute » présentent des scores très élevés. Pour l'« Eau », le rappel est de 100 %, la précision de 100 % et le F-Score de 100 %. Cela indique une très bonne classification de cette classe. Mais visuellement, nous remarquons une plusieurs confusions avec les zones d'ombres. Pour la « végétation haute », on a un rappel de 100 %, une précision de 85 % et un F-Score de 92 %). Cela indique une bonne distinction de ces classes, bien que quelques confusions aient eu lieu. Par exemple, en prenant le cas de classe « Végétation haute », on remarque que 2 pixels objets appartenant réellement à la classe « Végétation basse » ont été confondus avec la classe « Végétation haute ». Cette confusion est observée surtout dans la partie nord de l'image (Figure 9).
- Les « Bâtiments » affichent des scores plutôt faibles, avec un rappel de 62 %, une précision de 80 % et un F-Score égale de 70 %. Cela indique que plusieurs bâtiments ont été mal classés : 4 pixels objets en tant que « Routes » et 1pixel objets en tant que « Végétation basse ». De plus, 2 pixels objets de la classe « Routes » ont été confondus avec la classe « Bâtiments ».
- Les « Routes » affichent une précision de 83 % et un rappel de 67 %, qui signifie des pixels mal classés : 2 pixels objets en tant que « Bâtiment ».
- La classe « Sol nu » montre une performance remarquable avec un rappel de 80 %, signifiant que la plupart des pixels de sol nu ont été correctement identifiés. Cependant, un rappel de 66 % indique quelques erreurs avec d'autres types de classes : 1 pixel objet a été classé dans la catégorie « Routes ».

- La précision de la classe « Végétation basse » plutôt bonne, atteignant 85 %, mais son rappel est plus faible, à 75 %, ce qui signifie que certains pixels de végétation ont été classés dans une autre catégorie (Figure 9).
- Le F-Score moyen (83 %) indique une bonne classification dans l'ensemble.

1.2. Evaluation des protocoles tests

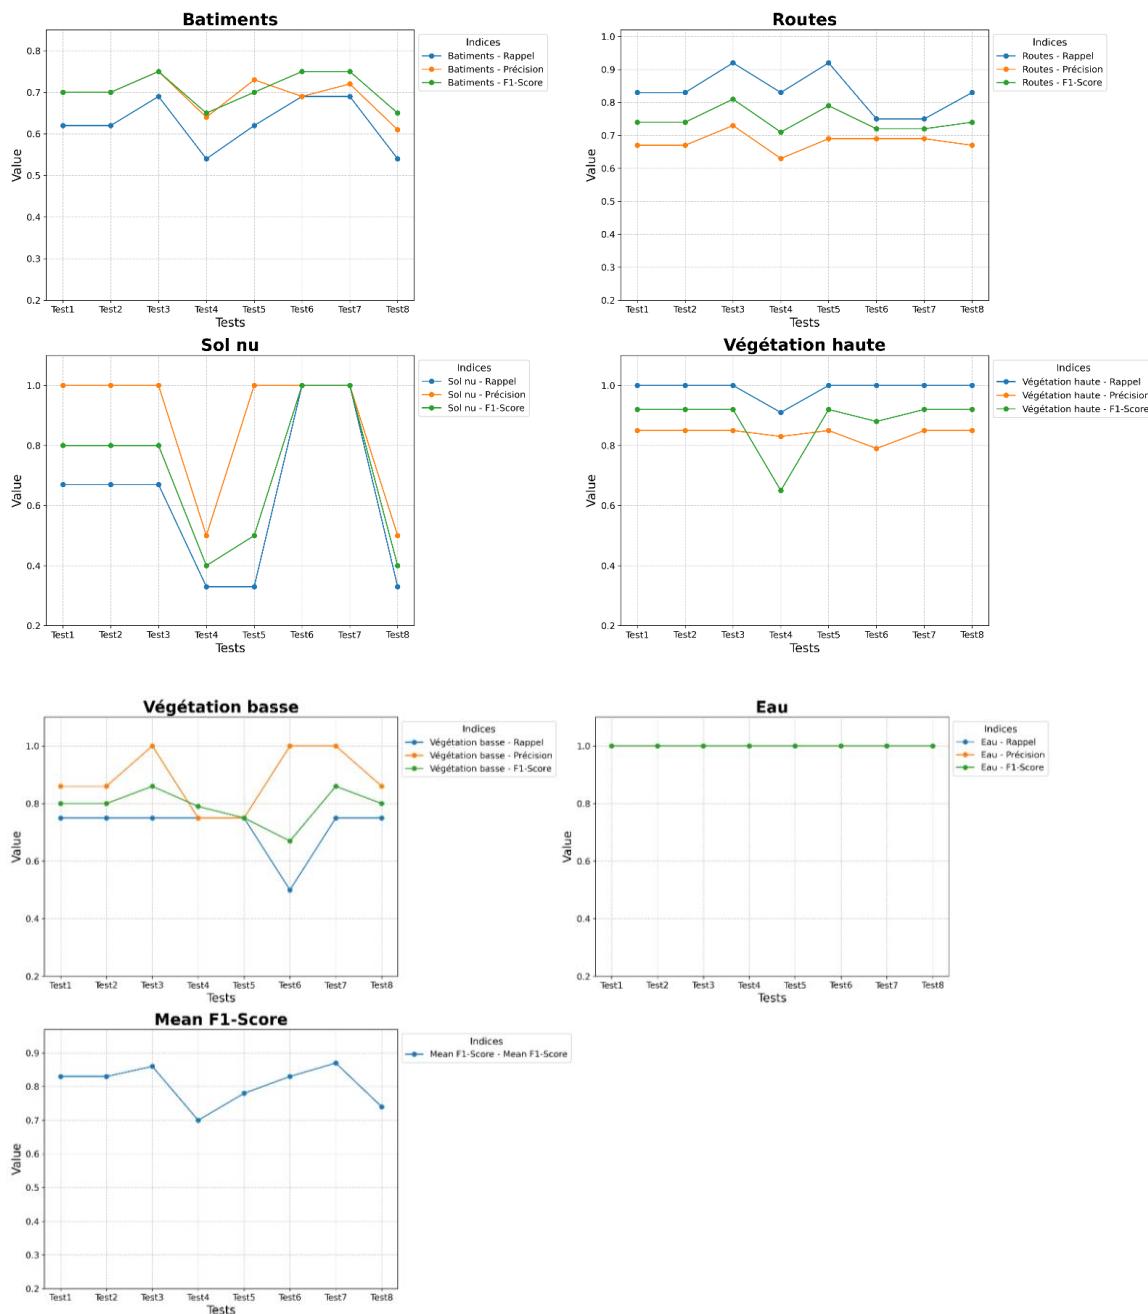


Figure 11 : graphique des résultats de la matrice de confusions des protocoles de tests avec la classification objet.

L'analyse des résultats nous permet de faire ressortir quelques points importants :

- **Classe « Bâtiments » :**
 - Une baisse de la performance est observée pour les tests 4 et 6, suggérant des confusions avec d'autres classes à l'ajout du MNE dans la classification (Annexe 3).

- **Classe « Routes » :**

- Les scores de classification des routes sont globalement élevés et constants, mais plus élevés pour le test 3 (rappel : 92 %, précision : 73 %, F-score : 81 %) et plus bas pour le test 6 et 7 (rappel : 75 %, précision : 69 %, F-score : 72 %) car confusion avec la classe « Bâtiments » (Annexe 3).

- **Classe « Sol nu » :**

- On observe des variations importantes dans ces scores, notamment une chute drastique à l'ajout du MNE (test 4 et test 8). Cependant dans les autres tests (test 1, 2, 3, 6, 7), les scores sont restés constants.

- **Classe « Végétation basse » :**

- Une légère baisse de performance est visible pour le test 4 et le test 6. Cependant, avec l'ajout d'indice tels que le NDWI (test 3) et les indices texturaux (test 7), les performances sont à leur plus haut niveau (F-score : 86 %).

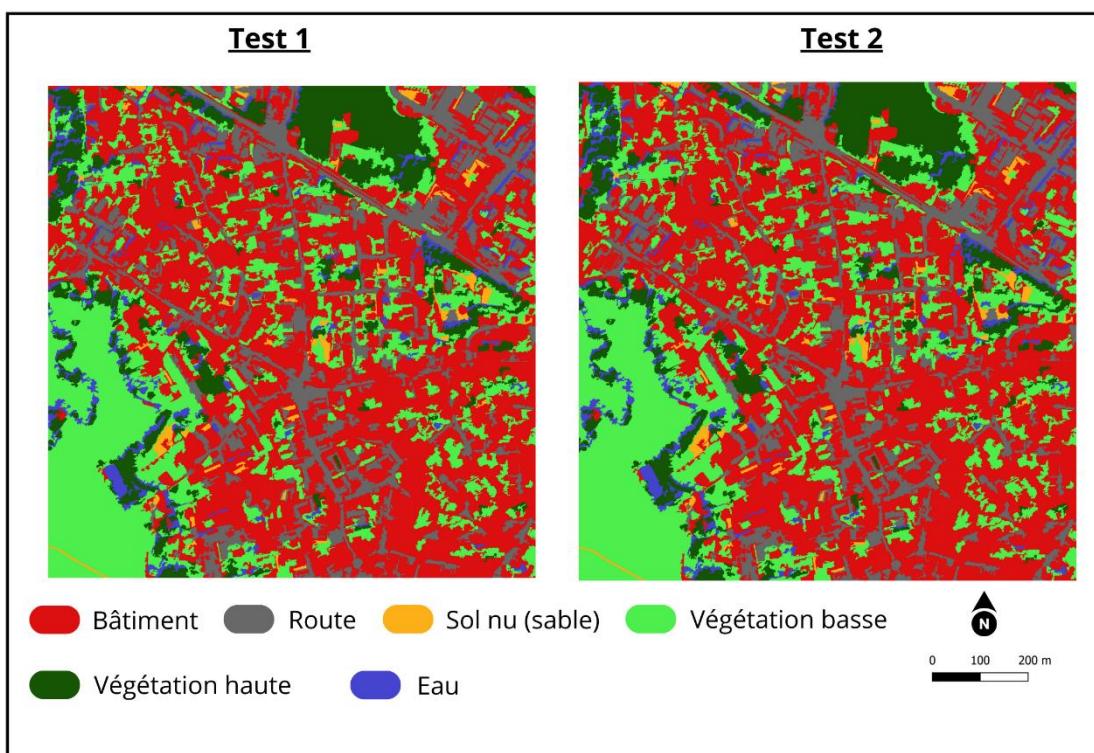
- **Classe « Végétation haute » :**

- On observe les mêmes performances pour tous les tests (rappel : 100 %, précision : 85 %, F-score : 92 %) sauf pour le test 4 où la performance est la plus faible (F-score : 65 %).

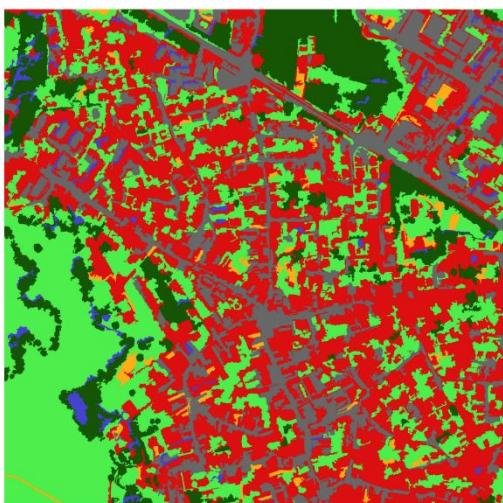
- **Classe « Eau » :**

- Pour cette classe, les scores restent constants et maximal (F-score : 100 %), indiquant une bonne classification.

En général, l'ajout des attributs exogènes entraîne une légère augmentation de la performance globale (F-score : 83 % pour les tests 1, 2, 5, 6, 7 et 86 % pour le test 3) par rapport à la classification de l'image de base (F-score : 82 %), mais une dégradation est observée pour les tests 4, 7 et 8 (F-score : 70 %, 70 % et 74 %). La Figure ci-dessous montre les résultats visuels des différentes classifications en fonction des tests.



Test 3

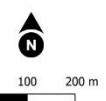


Test 4



Bâtimen^t Route Sol nu (sable) Végétation basse

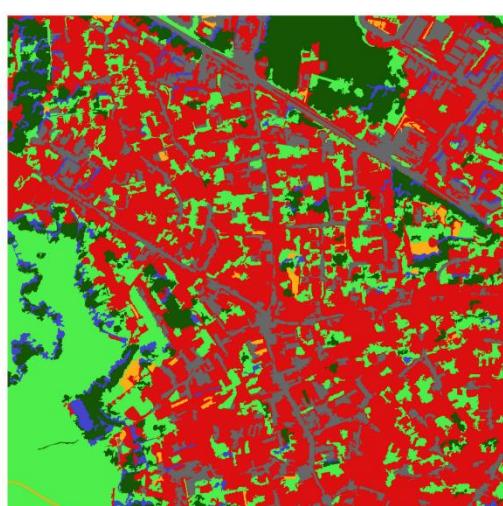
Végétation haute Eau



Test 5

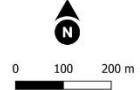


Test 6



Bâtimen^t Route Sol nu (sable) Végétation basse

Végétation haute Eau



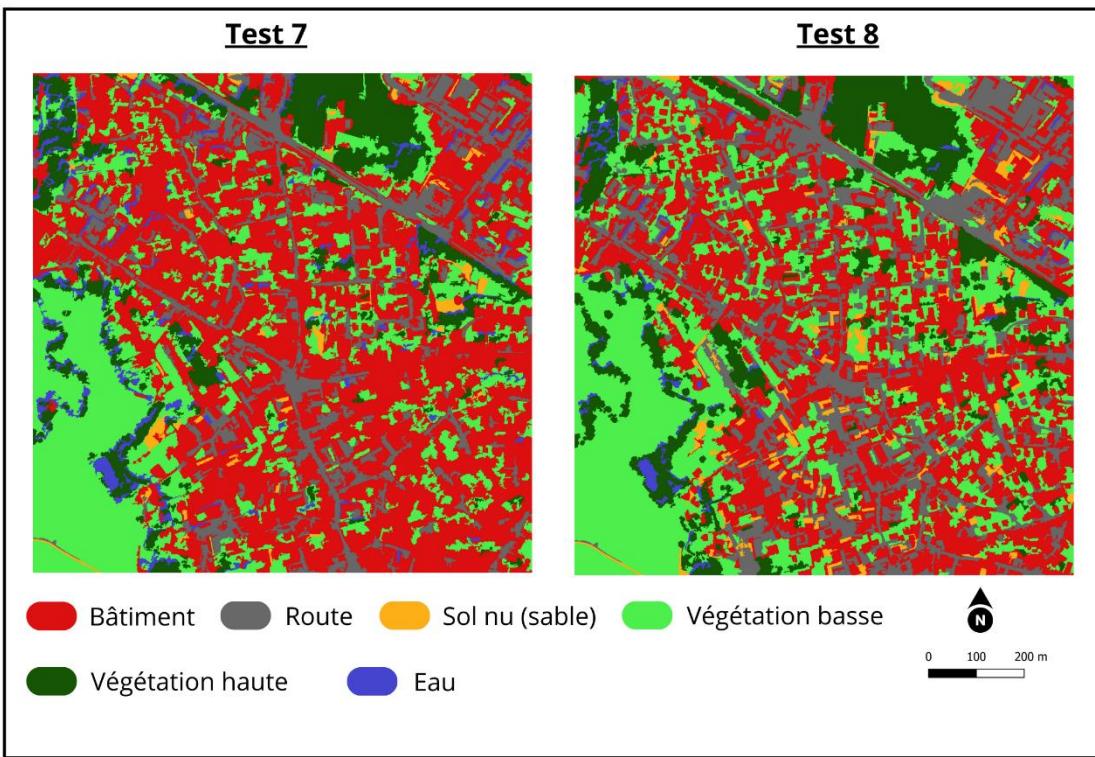


Figure 12 : Résultats visuels des différentes classifications des protocoles tests avec la méthode objet.

Visuellement, la classification du test 3 est la plus proche de la réalité, offrant une bonne distinction des classes selon l'image de base. Elle présente le deuxième meilleur F-score (86 %) parmi toutes les classifications, juste après le test 7 (87 %). Cependant, la classe « Eau » présente une forte confusion avec les zones sombres ou ombragées dans toutes les classifications, mais cette confusion est moins marquée pour le test 3.

Cette première partie a consisté à appliquer une classification de l'occupation du sol de notre image pléiades. Pour ce faire, nous avons utilisé la classification supervisée orientée ‘objet’ basée sur des concepts de la reconnaissance de formes, qui regroupe des pixels selon leurs propriétés géométriques, spectrales et contextuelles. L’analyse des performances des différents modèles (avec et sans indices exogènes) a révélé d’importantes variations statistiques et visuelles dans les résultats de la classification.

Dans la suite du rapport, nous adopterons la même démarche méthodologique pour réaliser une classification supervisée orientée ‘pixel’ afin de comparer les deux méthodes. Contrairement à l’approche objet, cette méthode attribue une classe à chaque pixel indépendamment de son contexte spatial.

2. Classification ‘Pixel’

2.1. Evaluation du modèle

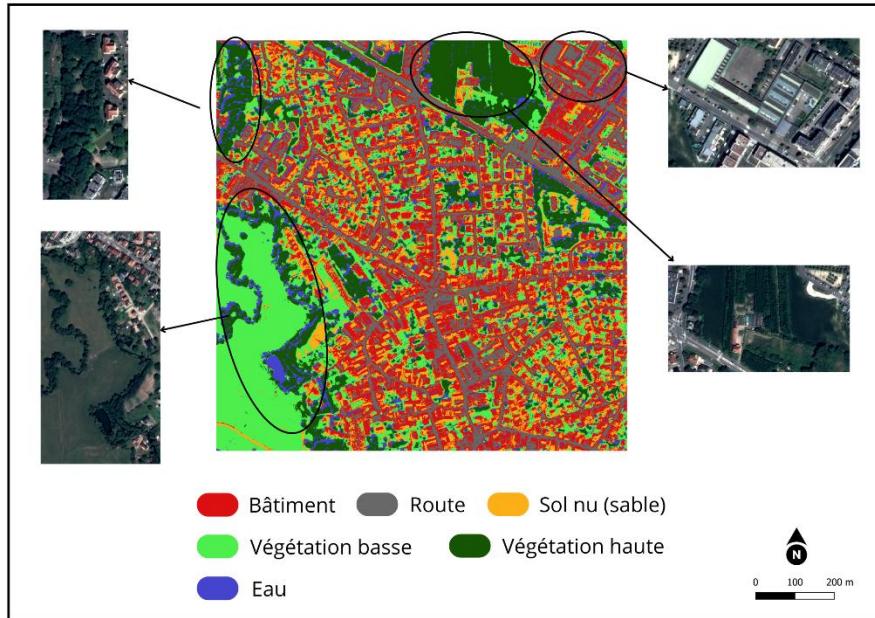


Figure 13 : classification pixel de l'image pléiades.

En examinant la carte, on constate plusieurs confusions dans la classification. Les zones sombres ont été classées comme « Eau ». La végétation basse est généralement bien distinguée, sauf dans le nord-ouest, où elle est confondue avec la végétation haute. De plus, il y a une confusion notable entre les classes « Bâtiments » et « Routes », certains bâtiments ayant été assimilés à des routes et vice-versa. L'analyse de la matrice de

confusion nous permet d'avoir plus de détails des résultats de classification.

	REFERENCE							
PREDICTION	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	Rappel	
	728	223	180	0	36	77	0,59	
	Routes	298	877	36	0	12	21	0,70
	Sol nu (sable)	83	16	1106	0	38	1	0,89
	Végétation haute	0	0	0	1131	48	65	0,91
	végétation basse	3	0	25	61	1147	8	0,92
	Eau	23	0	4	126	44	1047	0,84
Précision	0,64	0,79	0,82	0,86	0,87	0,86		
Classe	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau		
F-score	0,68	0,69	0,94	0,88	0,89	0,91		
Mean F-score	0,8							

Figure 14 : Matrice de confusion de la classification pixel de l'image pléiades.

En analysant la précision, le rappel et le F-scores des classes, on remarque que :

- Les classes « Végétation basse » et « Végétation haute » présentent des scores élevés (89 % pour la « Végétation basse » et 88 % pour la « Végétation haute »). Cependant, des pixels de la classe « Végétation haute » ont été classés comme « Végétation basse » et « Eau », et vice-versa.
- La classe « Sol nu » montre une bonne performance avec un rappel de 89 %, signifiant que la plupart des pixels de sol nu ont été correctement identifiés. Cependant, une précision de 82 % indique quelques erreurs avec d'autres classes : un total de 247 pixels confondus en tant que « Sol nu ».
- Les classes « Végétation basse » et « Végétation haute » obtiennent des scores élevés (89 % pour la « Végétation basse » et 88 % pour la « Végétation haute »). Cependant, des pixels de la classe « Végétation haute » ont été classés comme « Végétation basse » et « Eau », et vice-versa.
- La classe « Eau » présente des confusions avec toutes les classes, bien qu'elle ait un score de 91 %.
- Le F-Score moyen (80 %) indique une bonne classification dans l'ensemble.

2.2. Evaluation des tests de protocoles

Le protocole de test de la méthode « pixel » a été basé sur celui de la méthode « objet », et nous avons appliqué les mêmes tests. Les résultats des matrices de confusions sont présentés sous forme de graphique :

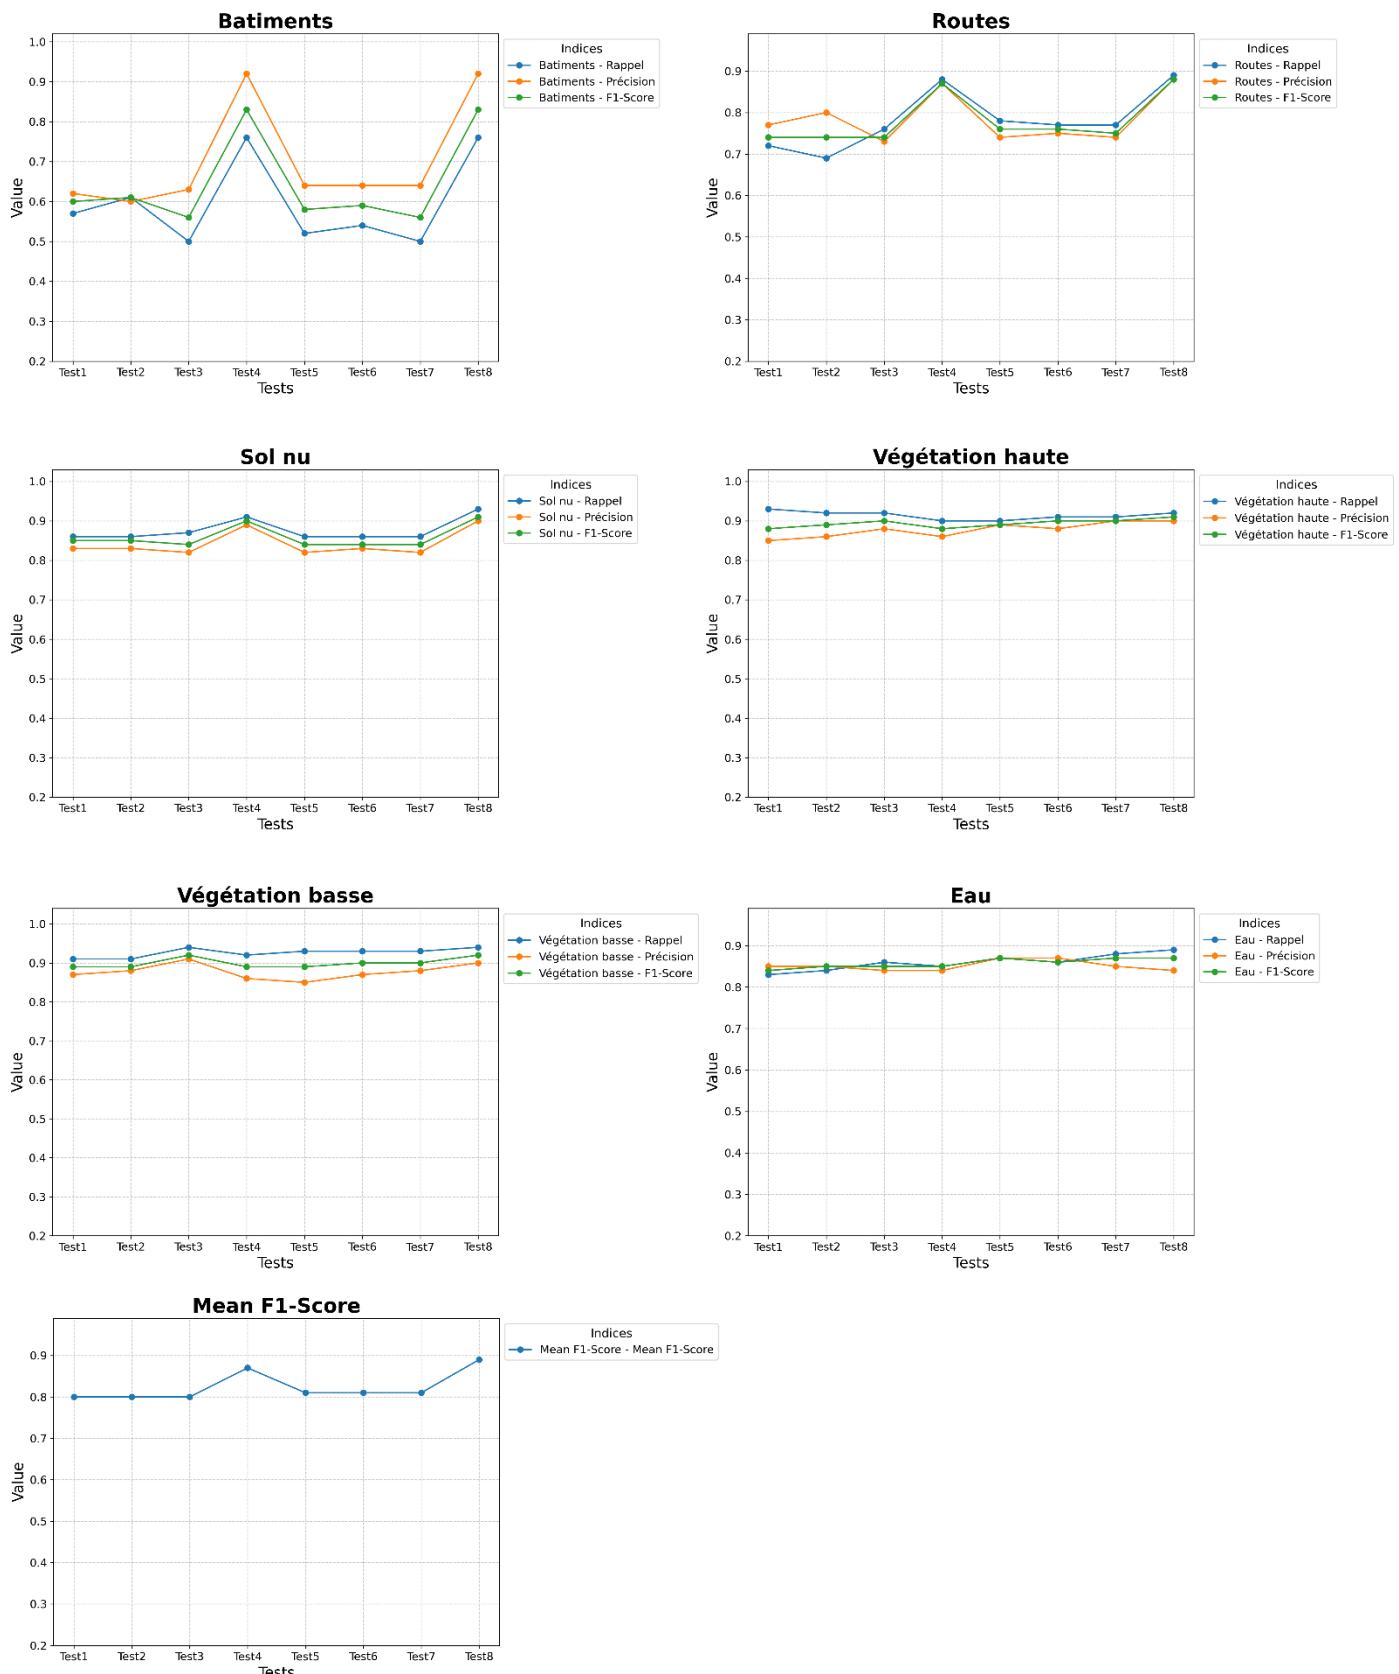


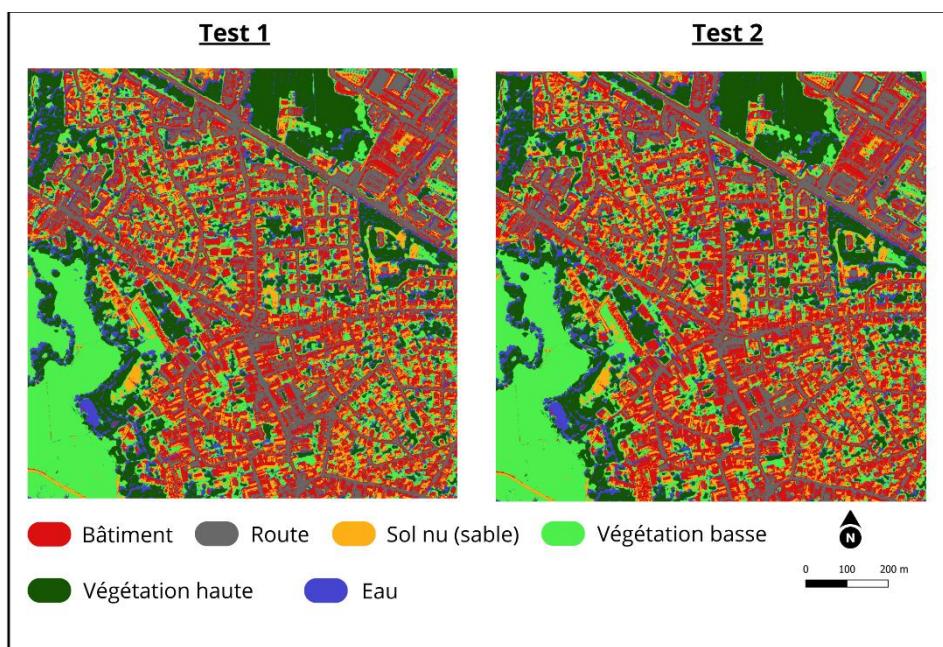
Figure 15 : graphique des résultats de la matrice de confusions des protocoles de tests avec la classification pixel.

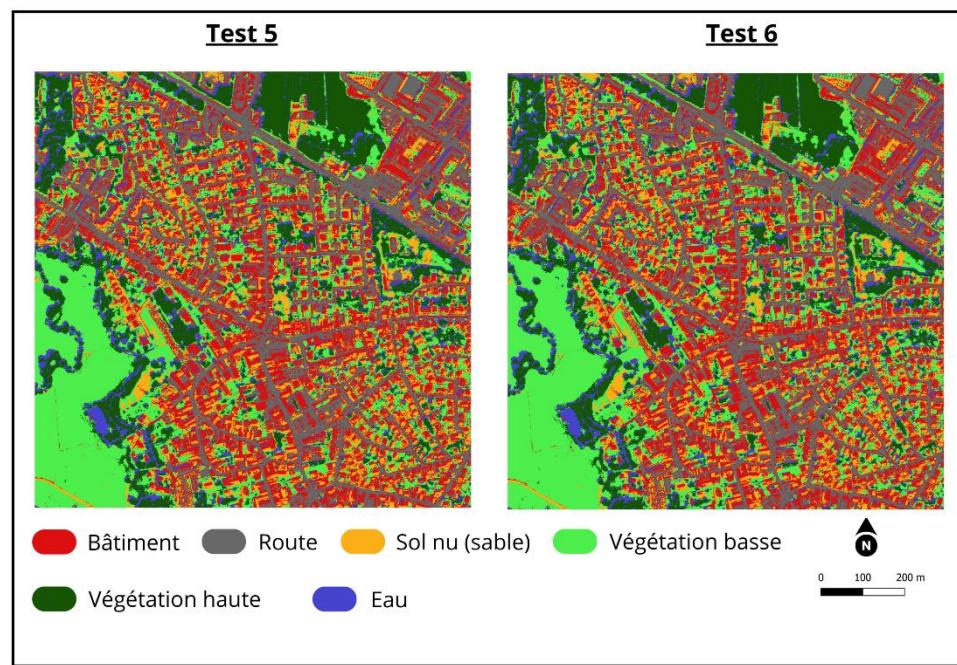
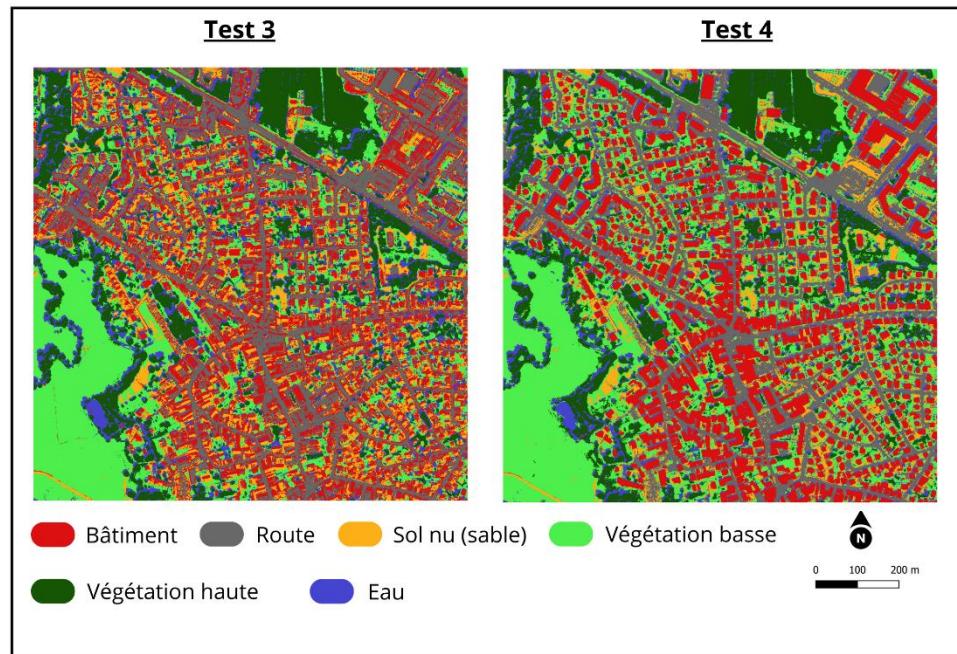
- Avec la classe « Bâtiments », on remarque le l'ajout du MNE (test 4 et test 8) a amélioré considérablement la classification celle-ci. On a un score de 83 %, largement supérieure à la première classification (sans indices exogène). Avec les autres tests, on observe plutôt des fluctuations selon l'indice ajouté.
- De même, la classe « Routes » à sa performance élevée avec les tests 4 et 8 (rappel : 87 %, précision : 87 %, F-score : 91 %).
- Le « Sol nu » à la performance la plus élevé pour le test 4 (rappel : 91 %, précision : 89%, F-score : 90 %). Cependant, chez les autres tests, on observe des scores approximativement égaux, tourant autour de 85 %.
- Les performances des classes « Végétation haute » et « Végétation basse » restent pratiquement inchangées pour tous les tests. Cependant, on observe une légère augmentation des performances de la classe « Végétation basse » avec l'ajout du NDWI au test 3.

En général, l'ajout des attributs exogènes entraîne une augmentation de la performance globale pour les tests 1 (F-score : 87 %) et 8 (F-score : 89) et 86 % pour le test 3.

Visuellement, en comparons les classifications obtenues avec celle de la classification sans indices exogènes nous constatons que les indices spectraux (NDVI, NDWI) (Test 1 et Test 2) et texturaux (dissimilarité et entropie) (Test 5, Test 6, Test 7), n'apportent pas de changement significatif à la classification. On observe toujours des confusions des zones sombres et ombragées avec la classe « Eau ». De même, la confusion entre les classes « Bâtiments » et « Routes » persiste. En revanche, l'apport des indices (image binaire ‘végétation’) dans le Test 3 et ‘MNE’ dans le Test 4 permet respectivement de mieux distinguer la végétation basse de la végétation haute et d'améliorer la classification des bâtiments et des routes.

Au regard de tous les tests effectués, qualitativement et quantitativement, la classification du test 8 est la meilleure classification supervisée orientée ‘pixel’.





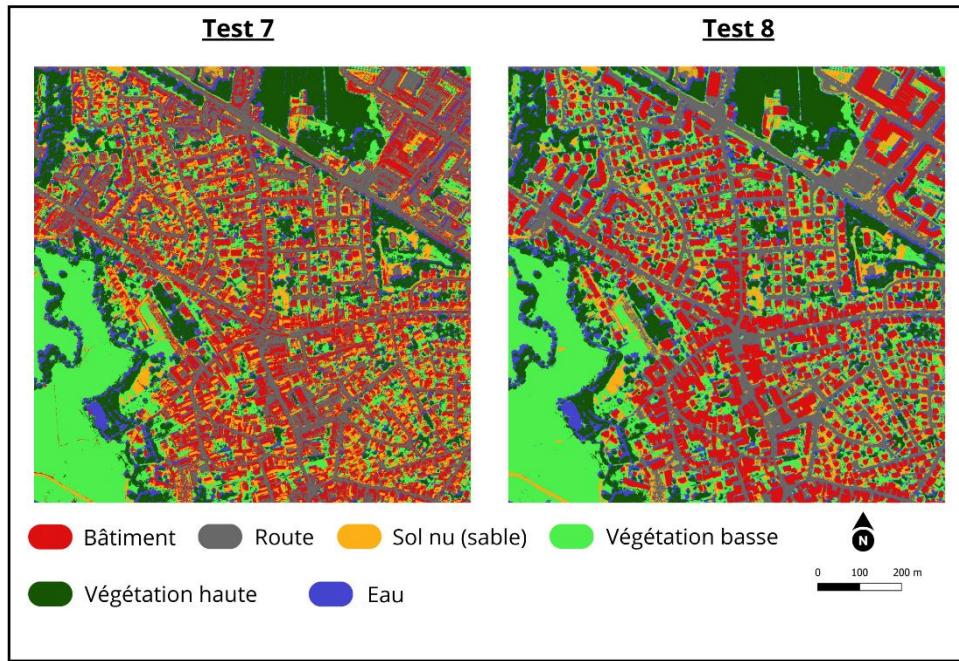


Figure 16 : Résultats visuels des différentes classifications des protocoles tests avec la méthode pixels.

3. Comparaison de la classification ‘pixel’ et de la classification ‘objet’

Pour comparer les deux classifications (orientée ‘objet’ et orientée ‘pixel’, nous avons choisi de d’utiliser les deux meilleures classifications en termes de score. C'est-à-dire la classification du test 7 (bandes R-V-B-PIR + entropie + dissimilarité) pour ‘l’objet’ et la classification du test 8 (bandes R-V-B-PIR + NDVI + NDWI + MNE+ entropie + dissimilitude) pour le ‘pixel’.

Méthode	Classes	Rappel	Précision	F-Score	F-score moyen
Objet	<i>Bâtiments</i>	0,69	0,75	0,72	0,87
	<i>Routes</i>	0,75	0,69	0,72	
	<i>Sol nu (sable)</i>	1	1	1	
	<i>Végétation haute</i>	1	0,85	0,92	
	<i>végétation basse</i>	0,75	1	0,86	
	<i>Eau</i>	1	1	1	
Pixel	<i>Bâtiments</i>	0,76	0,92	0,83	0,89
	<i>Routes</i>	0,89	0,88	0,88	
	<i>Sol nu (sable)</i>	0,93	0,90	0,91	
	<i>Végétation haute</i>	0,92	0,90	0,91	
	<i>végétation basse</i>	0,94	0,90	0,92	
	<i>Eau</i>	0,89	0,84	0,87	

Figure 17 : Résumé des matrices de confusion des meilleures classifications objet et pixel.

Dans l'ensemble, la classification pixel affiche un F-score moyen de 89 %, légèrement supérieur à celui de la classification objet (0,87), suggérant une performance légèrement améliorée lorsque d'avantage améliorée avec plus d'indice. Cependant, en considérant les mêmes bandes utilisées pour le pixel, le modèle pour la classification objet devient moins performant (74 %).

En analysant les résultats, on remarque que la classification pixel se démarque notamment pour les classes « Bâtiments », « Routes » et Végétation basse », obtenant des F-scores de 83 %, 88 % et 92 % contre 72 %, 72 % et 86 % pour la classification objet. L'ajout du MNE et du masque 'végétation' dans la classification pixel renforce la distinction des objets urbains et des formations végétales. Contrairement à la première classification (bande spectrale pléiades uniquement), où on avait respectivement comme score 68 %, 69 % et 89 %.

En revanche, la classification objet excelle dans la reconnaissance des classes homogènes comme le « Sol nu » et « Eau », avec des F-score parfaits (100 %). Il est important de prendre du recul sur ces résultats. En effet, le F-score est probablement surestimé malgré le fait que l'on possède un jeu d'entraînement et d'évaluation. Cependant, la classification pixel affiche également de bons résultats pour ces classes, tendant vers la réalité avec des F-scores de 91 % pour le sol nu et 87 % pour l'eau.

Cependant, lorsqu'on observe les résultats visuels (Figure 18), on remarque clairement que la classification pixel donne un résultat plus détaillé avec des pixels classés individuellement, tandis que la classification par objet donne un résultat plus uniforme en regroupant les pixels en régions homogènes. Sur les deux cartes (pixel et objet), la zone 2, qui correspond réellement à une parcelle agricole (image pléiades) a été classé en tant que « Végétation haute ». Certainement à cause de sa signature spectrale et sa teinte, qui ressemble beaucoup à celle de la « Végétation haute ». Sur l'image pléiades, on remarque que sa couleur est différente des autres parcelles agricoles, qui sont plus claires, probablement à cause des cultures actives dans cette zones par rapport aux autres parcelles. Soulignons que cette zone a été utilisée comme zone de validation lors de la sélection des données d'entraînement et de validation pour la classification objet, ce qui a potentiellement influencer les résultats. En ajoutant des indices exogènes (NDVI, masque de végétation), la classe n'a pas changé. On observe aussi une confusion entre la classe "Eau" et les zones sombres sur les deux cartes, notamment dans la classification par objet (zone 1), atteignant un score de 100 %. Cette confusion peut s'expliquer par des réponses spectrales similaires entre ces zones dans le domaine visible et proche infrarouge, où l'eau et les zones ombragées absorbent fortement le proche infrarouge. Cependant, l'indice NDWI n'a pas permis de faire cette distinction. En revanche, la classification pixel réduit cette erreur en classant chaque pixel individuellement en fonction de ses caractéristiques spectrales.

De plus, la confusion la plus marqué dans les deux classifications se trouve également entre les classes « Bâtiments » et « Routes ». Dans la classification objets, on a remarqué que l'apport du MNE n'a pas eu d'influence positive sur la bonne catégorisation de la classe « Bâtiments ». Avec l'apport des indices texturaux (dissimilitude et entropie), certains bâtiments, surtout de toit plats et clairs ont tout de même été classé en tant que « Routes » (zone 3). Cela peut s'expliquer par la similarité spectrale entre les routes et les toits des bâtiments. En effet, les toitures en bitumes sombres ont une réponse spectrale proche de l'asphalte des routes et les conditions d'éclairage (ex. ombre portée) peut modifier la réflectance et entraîner cette confusion. Cependant dans la classification pixel, une bonne distinction entre la classe « Routes » et « Bâtiments » a été observé. Certainement, avec l'ajout du MNE, l'algorithme de classification a pu mieux distinguer ces deux classes, attribuant les pixels de forte élévation aux bâtiments et ceux proches du sol aux routes. De plus, 'avec

l'ajout de l'entropie et la dissimilarité, les zones bâties ont pu être mieux distinguées des routes car ces indices mettent en évidence la variabilité des textures et des contrastes, améliorant ainsi la classification des deux classes.

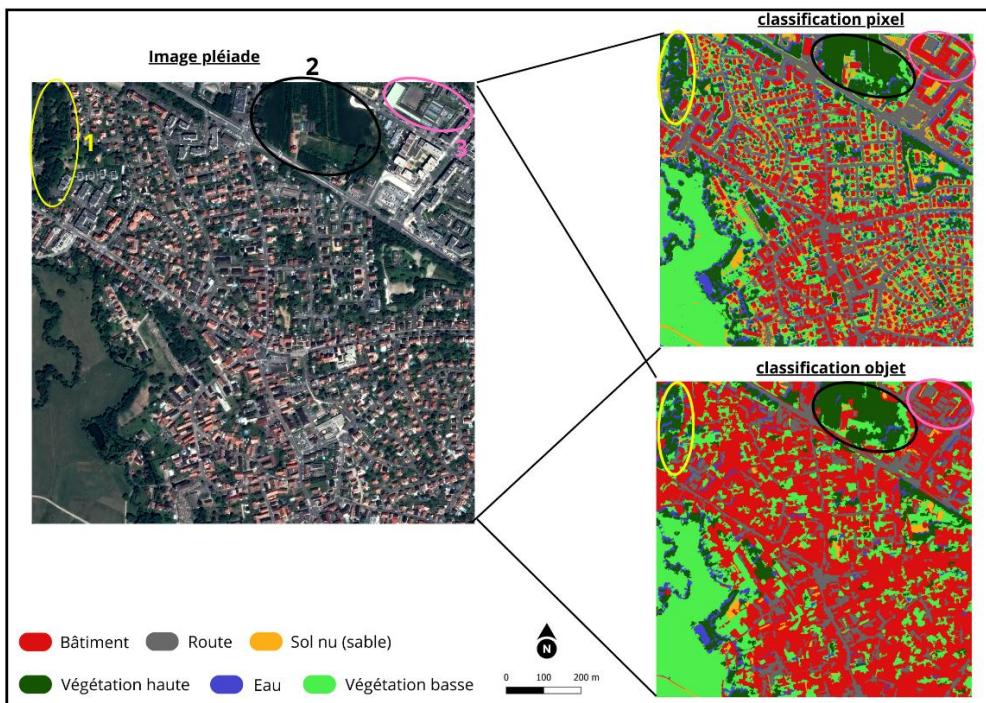


Figure 18 : Carte de classification des meilleures classifications objet et pixel.

4. Comparaison de nos classifications avec la donnée de référence

Afin de comparer nos classifications (pixel et objet) avec la donnée de référence, nous avons tout d'abord modifié la typologie de celle-ci pour qu'elle corresponde à la nôtre. Pour cela, nous avons regroupé certaines classes similaires en une seule (Figure 6).

La comparaison entre nos classifications et la donnée de référence OCSGE révèle quelques différences. La classification objet se rapproche davantage de l'OCSGE. Par exemple, la zone (2) est classée comme végétation basse dans la donnée de référence, alors que dans nos classifications (pixel et objet) elle est cataloguée comme végétation haute. Pour ce qui est de la catégorisation de la classe « Routes », la classification pixel correspond mieux à la donnée de référence en montrant des tracés de routes primaires, secondaires et tertiaires à certains endroits. Cependant, la classification objet montre ces tracés de routes, mais interrompus majoritairement par la classe « Bâtiments ».

La classe « végétation haute » est en grande partie similaire dans les deux classifications par rapport à la donnée de référence. Cependant, la classe « Eau » dans la donnée de référence inclut un cours d'eau et un plan d'eau sans ripisylves. Dans nos classifications, le plan d'eau est bien identifié, mais le cours d'eau est moins visible en raison des ripisylves. De plus, la donnée de référence ne montre pas de plans d'eau dans les zones de « végétation haute » ou au milieu des bâtiments, contrairement à nos classifications où ces plans d'eau apparaissent dans les forêts et entre les bâtiments. Cette comparaison appuie l'hypothèse selon laquelle la classe « Eau » a été surestimée dans nos différentes classifications.

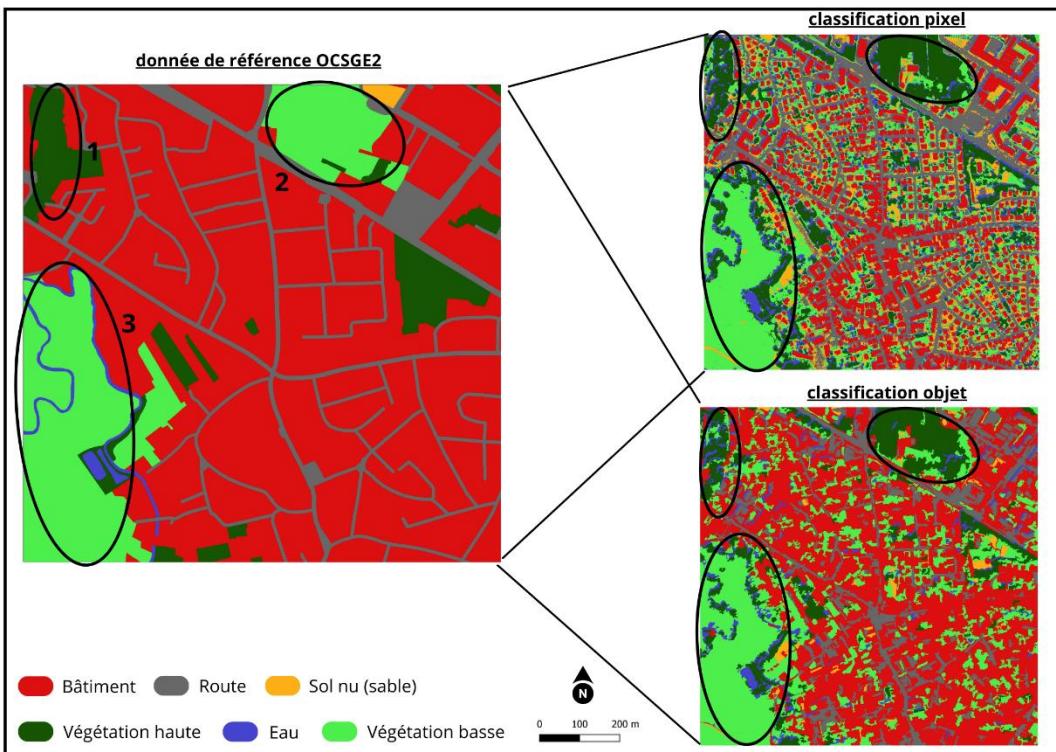


Figure 19 : Comparaison de la donnée de référence (OCSGE2) avec nos meilleures classifications (pixel et objet).

IV. Discussion

Les résultats obtenus à l'issus de ce travail mettent en évidence la supériorité de la classification supervisée orientée ‘pixel’ par rapport à l’approche orientée ‘objet’, notamment en ce qui concerne la précision globale et la capacité de discrimination entre certaines classes. Cette performance supérieure, est notamment due à l’intégration d’un large éventail d’indices exogènes tels que le NDVI, le NDWI, le MNE, ainsi que des indices texturaux et un masque de végétation. Cependant les indices spectraux (NDVI, NDWI) ajouter seul n’ont pas eu de grand effet sur la catégorisation des classes comme « végétation basse », « végétation haute » et « eau ». Néanmoins, l’ajout de tous les indices exogènes, a permis d’améliorer la séparabilité spectrale des classes, confirmant les travaux antérieurs de Baatz et Schäpe (2000) sur l’enrichissement des signatures spectrales.

En revanche, l’approche orienté objet a montré une performance globalement inférieure, en particulier dans la détection des routes et des surfaces construites. Cette moins bonne performance peut être attribuée à la forte dépendance à la qualité de la segmentation, comme souligné par Myint et al (2011). Cela vient mettre en cause les propos de Regniers (2014), soulignant qu’une image peu segmentée ou sur-segmentée n’a pas d’effet sur la classification. Par ailleurs, en analysant les matrices de confusion, on remarque que l’ajout de tous les indices exogènes n’a pas améliorer la distinction entre les classes mais plutôt diminuer jusqu’à obtenir un score de 74 %, contrairement à la classification de base, où on n’avait pas ajouté d’indices exogènes (83 %).

En ce qui concerne la performance thématique, la classification pixel s’est démarquée par une meilleure différenciation entre les classes « Routes » et « Bâtiments », souvent confondues dans l’approche objet grâce

notamment à l'ajout du MNE et des indices texturaux (entropie et dissimilarité), exploitant les différences de hauteur et de texture.

Par ailleurs, la confusion de la classe « Eau » avec les surfaces ombragées observées initialement dans les deux approches ont été mieux corrigées dans la classification pixel. Cette amélioration peut être due à la présence du masque végétation. Ces erreurs de confusion sont récurrentes dans l'environnements urbains denses et sont bien documentées dans la littérature. L'introduction d'une classe 'ombre' ou d'un masque d'ombre basé sur l'azimut solaire et la hauteur des objets pourrait encore améliorer la qualité des classifications.

La comparaison des classification obtenues avec la base de référence OCSGE montre une cohérence de la classification pixel avec la réalité observée, notamment pour les classes végétales et la classe « route ». La classification objet présente quant à elle une meilleure homogénéité spatiale avec la donnée de référence pour la classe « Bâtiments ».

On pourrait améliorer la classification en utilisant premièrement, des données multi-sources (par exemple couplage pléiades + LiDAR). Cela permettrait, notamment de mieux distinguer les objets trois dimensions comme les bâtiments. Deuxièmement, l'automatisation de la sélection des indices exogènes pertinents par des méthodes statistiques, pourrait potentiellement optimiser le rapport complexité et performance. Complexe dans la mesure où certains indices ajoutés individuellement ou à plusieurs n'a pas vraiment augmenté la performance de la classification. Il serait également intéressant, sur la même zone d'étude de comparer la segmentation en sortie avec différentes résolutions. Nous disposons dans notre cas d'une image pléiades à THR (50 cm), et plus l'échelle est grande, plus les indices texturaux apparaissent fins. Une trop haute précision au sol des images ne viendrait pas nécessairement améliorer significativement la classification. L'accroissement du détail peut entraîner la confusion dans les réponses spectrales des objets et créer une valeur ajoutée à l'intérieur des classes, ce qui peut diminuer leurs séparabilités.

Conclusion

Cette étude a permis d'évaluer et de comparer deux approches de classification supervisée, l'approche pixel et l'approche objet, appliquées à une image multispectrale Pléiades à très haute résolution, en utilisant l'algorithme Random Forest. L'objectif était de déterminer quelle méthode permettait une classification plus précise de l'occupation du sol en milieu urbain peu dense.

Les résultats ont montré que l'approche pixel était plus performante en termes de précision et de F-score. L'ajout d'indices exogènes tels que le NDVI, le NDWI, l'entropie, la dissimilarité, le MNE et un masque de végétation a permis d'améliorer la distinction entre certaines classes, comme les bâtiments et les routes. En revanche, l'approche objet, bien que plus robuste contre a montré des limites dues à la dépendance à la segmentation, pouvant entraîner des erreurs pour les objets mal délimités spatialement. De plus, les résultats ont également révélé que certaines confusions récurrentes, comme l'assimilation des zones ombragées à la classe eau, étaient mieux gérées avec l'approche pixel que l'objet.

Néanmoins, les deux méthodes restent dépendantes des jeux d'entraînement et d'évaluation acquis manuellement. Si une sémantique précise n'est pas définie, la construction de ces jeux peut varier en fonction de la personne réalisant cette étape manuelle. Cela souligne l'importance d'une définition précise des classes d'occupation du sol et d'une méthodologie cohérente pour la constitution de ces jeux de données.

Bibliographie

- Baatz, M., & Schäpe, A., 2000. Multiresolution Segmentation : an optimization approach for high quality multi-scale image segmentation.
- Beaumont, B., Grippa, T., Lennert, M., Stephenne, N., Zarougui, S., Jasselette, J.-C., Van de Vyvere, L. et Wolff, É. 2019. Vers une Méthodologie Opérationnelle de Cartographie à Très Haute Résolution Spatiale de L'occupation et de L'utilisation du Sol En Wallonie. *Dynamiques régionales*, 8(2), 15-33. <https://doi.org/10.3917/dyre.008.0015>
- Bengoufa, Soumia & Niculescu, Simona & Mihoubi, Mustapha & Belkessa, Rabah & Rami, Ali & Rabehi, Walid., 2024, Étude comparative des méthodes de classification pixel par pixel et orientée objet pour la détection et l'extraction automatique du trait de côte (cas du secteur côtier de Mostaganem à l'Ouest Algérien)
- Breiman L., 2001, Random Forests, *Machine Learning*, 45(1), p. 5-32. DOI : [10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324)
- Dedieu J.-P., Bornicchia F., Kerkache R. et Pella H., 1997, Apport des informations de texture en télédétection pour l'étude de l'occupation des sols / The contribution to land-use studies of textural analysis using remote sensing data, *Revue de géographie alpine*, 85(3), p. 9-26. DOI : [10.3406/rga.1997.3923](https://doi.org/10.3406/rga.1997.3923)
- Duda T. et Canty M., 2002, Unsupervised classification of satellite imagery: Choosing a good algorithm, *International Journal of Remote Sensing*, 23(11), p. 2193-2212. DOI : [10.1080/01431160110078467](https://doi.org/10.1080/01431160110078467)
- Lénaïg Sparfel, Françoise Gourmelon, Iwan Le Berre. APPROCHE ORIENTÉE-OBJET DE L'OCCUPATION DES SOLS EN ZONE CÔTIÈRE. *Teledetection*, 2010, 8 (4), pp.237-256. : <https://hal.science/hal-00559730>
- Myint S. W., Gober P., Brazel A., Grossman-Clarke S. et Weng Q., 2011, Per-pixel vs. object-based classification of urban land cover extraction using high spatial resolution imagery, *Remote Sensing of Environment*, 115(5), p. 1145-1161. DOI : [10.1016/j.rse.2010.12.017](https://doi.org/10.1016/j.rse.2010.12.017)
- Olivier Regniers., 2014 Méthodes d'analyse de texture pour la cartographie d'occupations du sol par télédétection très haute résolution : application à la forêt, la vigne et les parcs ostréicoles. Traitement du signal et de l'image [eess.SP]. Université de Bordeaux, 2014 : <https://theses.hal.science/tel-01152599v1>
- Proisy C., Couturon P. et Fromard F., 2007, Predicting and mapping mangrove biomass from canopy grain analysis using Fourier-based textural ordination of IKONOS images, *Remote Sensing of Environment*, 109(3), p. 379-392. DOI : [10.1016/j.rse.2007.01.009](https://doi.org/10.1016/j.rse.2007.01.009)
- Puissant A., Jean-Philippe Malet, O. Maquaire., 2006, Mapping landslide consequences in mountain areas ; a tentative approach with a semi-quantitative procedure.. Proceedings of Internationale Conference On Spatial Analysis and Geomatics : <https://hal.science/hal-01108696>
- Puissant A., Rougier S. et Stumpf A., 2014, Object-oriented mapping of urban trees using Random Forest classifiers, *International Journal of Applied Earth Observation and Geoinformation*, 26, p. 235-245. DOI : [10.1016/j.jag.2013.07.002](https://doi.org/10.1016/j.jag.2013.07.002)

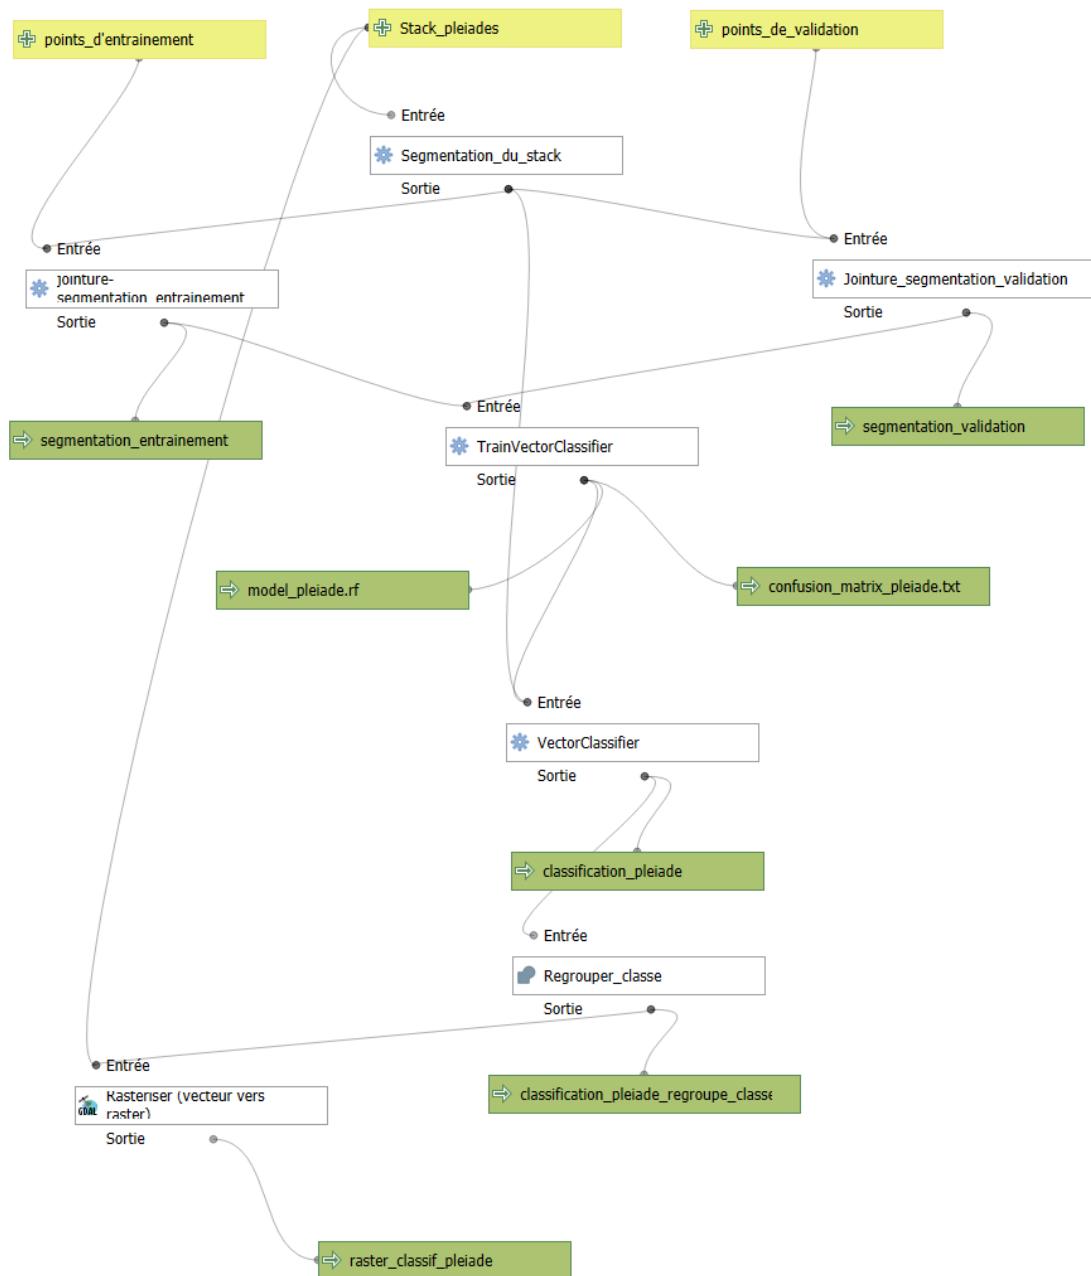
Rodriguez-Galiano V. F., Ghimire B., Rogan J., Chica-Olmo M. et Rigol-Sanchez J. P., 2012, An assessment of the effectiveness of a random forest classifier for land-cover classification, *ISPRS Journal of Photogrammetry and Remote Sensing*, 67, p. 93-104. DOI : [10.1016/j.isprsjprs.2011.11.002](https://doi.org/10.1016/j.isprsjprs.2011.11.002)

Teillet, Claire, et al. « Chapitre 5 - Texture des images satellite et caractérisation des milieux urbains favorables aux moustiques vecteurs ». Télédétection et modélisation spatiale, édité par Annelise Tran et al., Éditions Quæ, 2022, <https://books.openedition.org/quae/42854>.

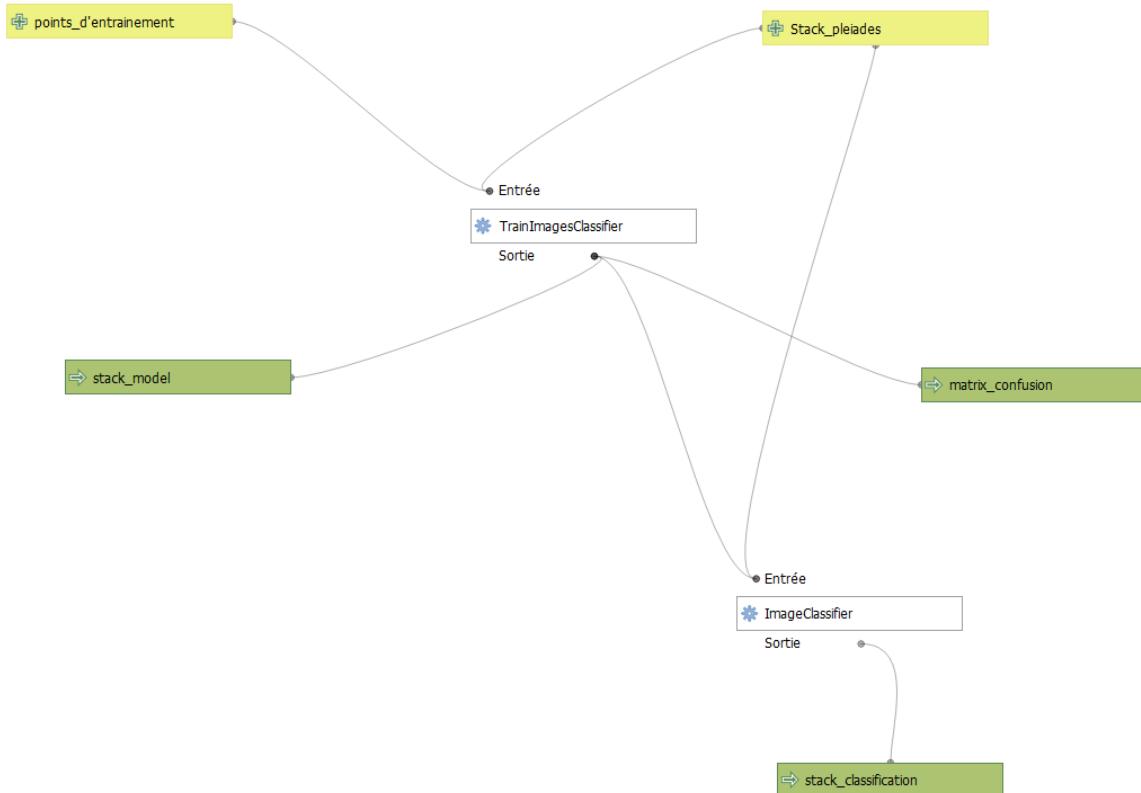
Valentine Judge., 2019, Apport de l'apprentissage automatique pour la modélisation et l'analyse des changements d'occupation du sol. Géographie. Université Bourgogne Franche-Comté : <https://hal.science/tel-02983188>

Annexe

Annexe 1 : Modeleur pour la classification Objet



Annexe 2 : Modeleur pour la classification Pixel



Annexe 3 : Matrices de confidences des protocoles de tests de la classification objet

Test 1								
PREDICTION	REFERENCE							
		Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	Rappel
	Bâtiment	8	4	0	0	1	0	0,62
	Routes	2	10	0	0	0	0	0,83
	Sol nu (sable)	0	1	2	0	0	0	0,67
	Végétation haute	0	0	0	11	0	0	1,00
	végétation basse	0	0	0	2	6	0	0,75
Eau	0	0	0	0	0	0	3	1,00
Précision	0,80	0,67	1,00	0,85	0,86	1,00		

Classe	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau
F-score	0,70	0,74	0,80	0,92	0,80	1,00
Mean F-score	0,83					

Test 2								
PREDICTION	REFERENCE							
		Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	Rappel
	Bâtiment	8	4	0	0	1	0	0,62
	Routes	2	10	0	0	0	0	0,83
	Sol nu (sable)	0	1	2	0	0	0	0,67
	Végétation haute	0	0	0	11	0	0	1,00
	végétation basse	0	0	0	2	6	0	0,75
Eau	0	0	0	0	0	0	3	1,00
Précision	0,80	0,67	1,00	0,85	0,86	1,00		
Classe	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau		
F-score	0,70	0,74	0,80	0,92	0,80	1,00		
Mean F-score	0,83							

Test 3

REFERENCE							
	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	Rappel
PREDICTION	Bâtiment	9	4	0	0	0	0,69
	Routes	1	11	0	0	0	0,92
	Sol nu (sable)	1	0	2	0	0	0,67
	Végétation haute	0	0	0	11	0	1,00
	végétation basse	0	0	0	2	6	0,75
	Eau	0	0	0	0	0	1,00
Précision		0,82	0,73	1,00	0,85	1,00	1,00
Classe	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	
F-score	0,75	0,81	0,80	0,92	0,86	1,00	
Mean F-score	0,86						

Test 4

REFERENCE							
	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	Rappel
PREDICTION	Bâtiment	7	5	1	0	0	0,54
	Routes	2	10	0	0	0	0,83
	Sol nu (sable)	0	1	1	0	1	0,33
	Végétation haute	0	0	0	10	1	0,91
	végétation basse	0	0	0	2	6	0,75
	Eau	0	0	0	0	0	1,00
Précision		0,78	0,63	0,50	0,83	0,75	1,00
Classe	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	
F-score	0,64	0,71	0,40	0,65	0,79	1,00	
Mean F-score	0,70						

Test 5

REFERENCE							
	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	Rappel
PREDICTION	Bâtiment	8	4	0	0	1	0,62
	Routes	1	11	0	0	0	0,92
	Sol nu (sable)	0	1	1	0	1	0,33
	Végétation haute	0	0	0	11	0	1,00
	végétation basse	0	0	0	2	6	0,75
	Eau	0	0	0	0	0	1,00
Précision		0,89	0,69	1,00	0,85	0,75	1,00
Classe	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	
F-score	0,73	0,79	0,50	0,92	0,75	1,00	
Mean F-score	0,78						

Test 6

REFERENCE							
	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	Rappel
PREDICTION	Bâtiment	9	4	0	0	0	0,69
	Routes	3	9	0	0	0	0,75
	Sol nu (sable)	0	0	3	0	0	1
	Végétation haute	0	0	0	11	0	1
	végétation basse	1	0	0	3	4	0,5
	Eau	0	0	0	0	0	1
Précision		0,69	0,69	1,00	0,79	1,00	1,00
Classe	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	
F-score	0,69	0,72	1,00	0,88	0,67	1,00	
Mean F-score	0,83						

Test 7

REFERENCE							
	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	Rappel
PREDICTION	Bâtiment	9	4	0	0	0	0,69
	Routes	3	9	0	0	0	0,75
	Sol nu (sable)	0	0	3	0	0	1,00
	Végétation haute	0	0	0	11	0	1,00
	végétation basse	0	0	0	2	6	0,75
	Eau	0	0	0	0	0	1,00
Précision		0,75	0,69	1,00	0,85	1,00	1,00
Classe	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	
F-score	0,72	0,72	1,00	0,92	0,86	1,00	
Mean F-score	0,87						

Test 8

REFERENCE							
	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	Rappel
PREDICTION	Bâtiment	7	5	1	0	0	0,54
	Routes	2	10	0	0	0	0,83
	Sol nu (sable)	1	0	1	0	1	0,33
	Végétation haute	0	0	0	11	0	1,00
	végétation basse	0	0	0	2	6	0,75
	Eau	0	0	0	0	0	1,00
Précision		0,70	0,67	0,50	0,85	0,86	1,00
Classe	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	
F-score	0,61	0,74	0,40	0,92	0,80	1,00	
Mean F-score	0,74						

Annexe 4 : Matrices de confidences des protocoles de tests de la classification pixel

Test 1

REFERENCE								
	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	Rappel	
PREDICTION	Bâtiment	713	258	155	0	35	83	0,57
	Routes	280	891	33	0	17	23	0,72
	Sol nu (sable)	125	3	1074	0	41	1	0,86
	Végétation haute	0	0	0	1154	28	62	0,93
	végétation basse	3	0	27	76	1128	10	0,91
	Eau	30	0	3	135	43	1033	0,83
Précision		0,62	0,77	0,83	0,85	0,87	0,85	
Classe	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau		
F-score	0,60	0,74	0,85	0,88	0,89	0,84		
Mean F-score	0,80							

Test 2

REFERENCE								
	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	Rappel	
PREDICTION	Bâtiment	759	213	157	0	36	79	0,61
	Routes	326	853	31	0	12	22	0,69
	Sol nu (sable)	131	2	1073	2	35	1	0,86
	Végétation haute	2	0	0	1143	33	66	0,92
	végétation basse	5	0	25	72	1132	10	0,91
	Eau	34	0	3	116	44	1047	0,84
Précision		0,60	0,80	0,83	0,86	0,88	0,85	
Classe	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau		
F-score	0,61	0,74	0,85	0,89	0,89	0,85		
Mean F-score	0,80							

Test 3

REFERENCE							
	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	Rappel
PREDICTION	Bâtiment	620	339	172	1	25	87 0,50
	Routes	228	944	32	0	13	27 0,76
	Sol nu (sable)	112	14	1080	0	32	6 0,87
	Végétation haute	0	0	2	1142	35	65 0,92
	végétation basse	4	0	34	28	1164	14 0,94
	Eau	25	0	3	126	15	1075 0,86
	Précision	0,63	0,73	0,82	0,88	0,91	0,84

Classe	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau
F-score	0,56	0,74	0,84	0,90	0,92	0,85
Mean F-score	0,80					

Test 4

REFERENCE							
	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	Rappel
PREDICTION	Bâtiment	944	121	63	0	31	85 0,76
	Routes	50	1093	48	0	13	40 0,88
	Sol nu (sable)	29	44	1131	0	39	1 0,91
	Végétation haute	2	0	2	1115	63	62 0,90
	végétation basse	1	2	27	55	1150	9 0,92
	Eau	0	3	4	131	43	1063 0,85
	Précision	0,92	0,87	0,89	0,86	0,86	0,84

Classe	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau
F-score	0,83	0,87	0,90	0,88	0,89	0,85
Mean F-score	0,87					

Test 5

REFERENCE							
	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	Rappel
PREDICTION	Bâtiment	651	320	161	0	33	79 0,52
	Routes	212	971	33	0	11	17 0,78
	Sol nu (sable)	119	14	1070	0	40	1 0,86
	Végétation haute	1	0	2	1114	71	56 0,90
	végétation basse	5	0	28	41	1158	12 0,93
	Eau	24	0	3	91	44	1082 0,87
	Précision	0,64	0,74	0,82	0,89	0,85	0,87

Classe	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau
F-score	0,58	0,76	0,84	0,89	0,89	0,87
Mean F-score	0,81					

Test 6

REFERENCE							
	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	Rappel
PREDICTION	Bâtiment	671	307	157	0	33	76 0,54
	Routes	221	962	35	0	11	15 0,77
	Sol nu (sable)	120	17	1066	0	40	1 0,86
	Végétation haute	2	0	1	1131	52	58 0,91
	végétation basse	4	1	28	45	1156	10 0,93
	Eau	28	1	3	102	43	1067 0,86
	Precision	0,64	0,75	0,83	0,88	0,87	0,87

Classe	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau
F-score	0,59	0,76	0,84	0,90	0,90	0,86
Mean F-score	0,81					

Test 7

REFERENCE							
PREDICTION	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	Rappel
	Bâtiment	628	324	169	0	27	96 0,50
	Routes	215	961	37	0	10	21 0,77
	Sol nu (sable)	118	16	1075	0	34	1 0,86
	Végétation haute	2	0	2	1128	54	58 0,91
	végétation basse	3	1	32	36	1160	12 0,93
	Eau	21	1	3	87	39	1093 0,88
Précision	0,64	0,74	0,82	0,90	0,88	0,85	
Classe	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	
F-score	0,56	0,75	0,84	0,90	0,90	0,87	
Mean F-score	0,81						

Test 8

REFERENCE							
PREDICTION	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	Rappel
	Bâtiment	943	123	65	0	28	85 0,76
	Routes	51	1108	36	0	10	39 0,89
	Sol nu (sable)	29	28	1152	2	31	2 0,93
	Végétation haute	0	1	0	1150	29	64 0,92
	végétation basse	0	3	21	36	1170	14 0,94
	Eau	0	2	4	90	36	1112 0,89
Précision	0,92	0,88	0,90	0,90	0,90	0,90	0,84
Classe	Bâtiment	Routes	Sol nu (sable)	Végétation haute	végétation basse	Eau	
F-score	0,83	0,88	0,91	0,91	0,92	0,87	
Mean F-score	0,89						